



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位論文

다중 모델 기반의 PDA를 이용한 다
중 표적 추적을 위한 실시간 알고리즘

Fast Algorithm of Multi-target Tracking
using Multi-Model and Probabilistic Data
Association

金 恩 奭

漢陽大學校 大學院

2012年 2月

碩士學位論文

다중 모델 기반의 PDA를 이용한 다
중 표적 추적을 위한 실시간 알고리즘

Fast Algorithm of Multi-target Tracking
using Multi-Model and Probabilistic Data
Association

指導教授 朴 章 炫

이 論文을 工學碩士 學位論文으로 提出합니다.

2012年 2月

漢陽大學校 大學院
知能형로봇工學科

金 恩 奭

이 論文을 金恩奭의 碩士學位 論文으로 認准함.

2012年 2月

審査 委員長 서 일 홍 (인)

審 査 委 員 박 중 현 (인)

審 査 委 員 박 장 현 (인)

漢陽大學校 大學院

차 례

차례.....	i
요지.....	ii
제 1 장 서론.....	1
1.1 연구배경	1
1.2 선행연구	3
1.3 연구목표	5
제 2 장 PDAF를 활용한 센서 퓨전 알고리즘	7
2.1 센서 퓨전의 소개.....	7
2.2 Interacting Multiple Model의 소개.	8
2.3 IMM의 이론	10
2.4 Probabilistic Data Association Filter의 소개	21
2.5 PDAF의 이론.....	22
2.6 IMM-PDAF	43
제 3 장 MMPDAM을 활용한 센서 퓨전	45
3.1 다중 모델 기반의 확률적 데이터 결합 기법.....	47
3.2 MMPDAM의 기초 이론	50
3.3 IMM-PDAMF	61
제 4 장 시뮬레이션	62
4.1 시뮬레이션 환경 소개	62
4.2 각 경우별 시뮬레이션	63
제 5 장 결론.....	70
참고문헌.....	71
Abstract	73
감사의 글	74

요 지

오늘날 지능형 차량 개발, 지능형 로봇 개발 등의 다양한 차세대 퓨전 기술 개발을 위해서 지속적인 지원과 노력을 이어가고 있다.

지능형 로봇을 위해서는 상황인식 기술, 지능형 판단 기술, 지능형 제어기술 등의 기술이 필요하다. 이들 중 상황인식 기술은 다시 센서 기술과 센서의 데이터를 처리 기술로 분류 한다. 요즘 센서 퓨전 기술이란 거론 된다. 센서퓨전은 센서 기술과 센서 데이터 처리 기술의 중간쯤에 위치하는 기술이다. 그럼 왜 이런 기술이 등장 하였을까? 오늘날 레이저, 쌍안카메라, 레이다, 라이다, 초음파, GPS 등등 다양한 기능을 가진 서로 다른 센서들이 존재한다. 하지만, 어느 센서든지 인간의 인지 능력에 비하면 형편없을 정도이다. 그래서, 서로 다른 센서들 혹은 동일한 센서들 여럿을 마치 하나의 센서가 처리한 것처럼 퓨전하는 원리를 필요로 하게 되었다.

이런 센서 퓨전 기술의 핵심은 서로 다른 특징점 혹은 동일한 특징점들을 퓨전하여서 정확한 객체 상태를 표현하는 것이다.

본 논문에서는 이러한 시스템을 개발하기 위해서 핵심이 되는 실시간 다중 목표 추적 시스템에 대한 새로운 알고리즘을 제안하고자 한다. 이 알고리즘은 종래의 IMM-PDAF의 연산량을 크게 개선한 장점과 모델 별로 다양한 필터들을 서로 호환해서 사용하기 편한 장점을 가진다. 본 논문에서는 동일한 조건하에서 종래의 시스템과 새로 제안하는 시스템의 정확성 및 연산량의 개선 정도를 시뮬레이션 하고 비교 설명하고자 한다.

제 1 장 서론

1.1 연구배경

현대시대에서는 무인 자동차를 개발해서 사람이 아닌 자동차가 스스로 운전해 주길 바란다. 이유는 사람보다 컴퓨터가 보다 안전하고 편안하게 운전 할 수 있을 것이라고 기대하기 때문이다. 또한, 가사 로봇을 만들어 여러 용도로 사람을 도와 줄 수 있기를 기대하고 있다. 하지만, 이러한 지능형 시스템을 가진 로봇들을 만들기 위해서는 사람만큼의 상황인식을 로봇이 수행 할 수 있어야 한다. 이러한 상황인식은 센서들을 통해서 가능해 진다. 하지만, 어느 한가지 센서 만으로는 사람만큼의 상황인식을 로봇이 하도록 할 수는 없다는 것이 현대 과학 기술의 결론이다. 그래서, 오늘날 연구자들은 서로 다른 특성을 지닌 다수의 센서들 혹은 동일한 센서들을 가장 효과적으로 퓨전시키기 위해서 꾸준한 노력을 하고 있다. 하지만, 센서 데이터들간의 퓨전 기술은 최근에 들어서 그 필요성이 제기 되었으므로 센서 데이터들간의 퓨전 기술에 대한 표준 해법을 결정하기에는 시기 상조이다.

센서 데이터들간의 퓨전 기술의 기본 구조는 다음과 같이 생각할 수 있다. 첫째, 목표를 나타내는 트랙들의 생성, 유지, 제거를 관리하는 Track Management. 둘째, 목표의 상태를 정확히 추종하기 위한 필터. 셋째, 센서의 성능에 상관없이 필터 처리가 가능하도록 센서 측정값을 관리해주는 데이터 결합 기법(Data Association : DA). 등으로 나누어 생각해 볼 수 있다.

센서 데이터들간의 퓨전 기술의 구조 중 필터 기술과 데이터 결합 기술이 퓨전 기술의 성능을 좌우한다.

이러한 기술들의 종류로는 IMM-PDAF(Interacting Multiple Model Probabilistic Data Association), JPDA(Joint Probabilistic Data Association), GPB1(First order Generalized Pseudo-Bayesian), GPB2(Second order Generalized Pseudo-Bayesian), MHT(Multiple Hypothesis Tracking) 등이 있다. 센서 퓨전 기술의 특성상 알고리즘 처리가 가급적 실시간에 가까워야 하고 또한 어떠한 돌발 상황에서도 추종이 가능해야 한다. 이러한 특성을 볼 때, IMM-PDAF가 지금까지 기술들 중에서 좋은 평가를 받고 있다. 하지만, 실제로 IMM-PDAF를 Track Management와 함께 사용하면 IMM-PDAF의 수행 횟수에 의해서 실시간성을 보장하지 못한다는 것이 일반적인 견해이다.

그래서, 본 논문에서는 IMM-PDAF기술을 출발지로 해서 실제 환경에서 실시간성을 보장 할 수 있는 센서 퓨전 기술을 만들어 보고자 한다.

1.2 선행연구

이번 연구에서는 데이터 결합 기법(Data Association : DA)을 이용한 물체 추적 시스템(Target Tracking System) 개발에 관해서 수행하였다. 물체 추적 시스템에서 데이터 결합 기법은 목표의 상태를 추종하기 위해서 목표와 관련성 높은 다수의 측정값들로부터 목표의 측정값을 선택 혹은 생성해 내는 처리 기법이다. 가령, 레이더에서 관심 있는 목표를 추적하려고 할 때, 먼저 측정값의 존재가 예상 되어지는 유효 영역(Validation region : VR)을 설정한다. 유효 영역 안에 존재하는 측정값들과 데이터 결합 시켜서 목표를 추종하게 된다. 단일 목표에 대한 데이터 결합 기법은 NNF(Nearest Neighbor Filter), SNF(Strongest-Neighbor Filter) 그리고, PDA(Probabilistic Data Association)기법이 있다.[1-3] NNF는 예측하는 측정값에 가장 가까이 있는 측정값을 목표의 측정값으로 간주하고 나머지 측정값은 무시하는 데이터 결합 기법이다. SNF는 각 측정값의 가능성 지수를 가까운 정도 및 가중치를 이용해서 표현하고 이 값이 가장 높은 측정값을 목표의 측정값으로 간주하는 데이터 결합 기법이다. NNF과 SNF 기법들은 잡음 혹은 관심 없는 물체들의 밀도 값이 높아질수록 또는 목표의 검지 확률(Probability of Detection : P_D)이 떨어질수록 목표의 상태 추종이 실패하기 쉬워진다. 이러한 문제점에 대한 대안으로는 PDA가 있다. PDA는 목표의 검지 확률 값을 알고 있음의 가정을 가진다. 목표의 검지 확률 값 그리고 유효 영역 안에 목표의 실제 측정값이 있을 확률(Probability of Gating : P_G)를 이용해서 확률적으로 목표의 측정값을 계산하는 기법이다.

PDA기법은 다중 목표를 위한 데이터 결합 기법인 JPDA(Joint Probabilistic Data Association), MHT(Multiple Hypothesis Tracking) 그리고 IMM-PDAF기법으로 발전 되어 왔다.[1, 4, 5] JPDA는 다수의 측정값과 다수의 목표들을 데이터 결합시키고 확률적으로 통합시켜서 다중의 목표를 추종하게 된다. MHT는 각 측정값들의 순서에서 목표가 존재할 확률을 ML(Maximum Likelihood)에 따라서 평가함으로써 JPDA 보다는 더욱 강인하게 다중 목표를 추종 할 수 있다. 하지만 JPDA와 MHT는 너무 많은 연산 량 때문에 사실상 사용이 어렵다.[6] 이러한 문제의 대안으로 IMM-PDAF가 있다. IMM은 목표가 준수할 수 있는 다수의 모델을 설정하고 설정된 모델에 따라서 필터를 거친 목표의 상태 값을 확률적으로 통합함으로써 최종 목표의 상태 값을 추종한다. 하지만 IMM-PDAF 기법을 Track Management와 함께 연동하게 되면, PDAF의 시행 횟수가 너무 많아서 실시간성을 만족 못하는 문제를 가지고 있다.

따라서, 본 논문에서는 기존의 IMM-PDAF의 정확성은 유지하면서도 연산시간을 크게 개선하기 위해서 연구를 시작하였다. 본 논문에서는 새롭게 개발한 알고리즘인 IMM-PDAMF (Interacting Multi-Model Probabilistic Data Association Measure and Filter)를 소개하고, IMM-PDAF와 연산량 및 정확성을 비교하여서 IMM-PDAMF의 성능을 인증하고자 한다.

1.3 연구목표

선행연구에서 설명하였듯이 기존의 센서 퓨전 기술인 IMM-PDAF를 사용한 Track Management 운영 방식은 실시간 처리 능력을 기대하기 어렵다. 또한, IMM-PDAF는 다음 두가지 문제점을 가지고 있다.

첫째, PDA의 기본 원리를 따라서 필터 업데이트를 위한 측정값을 추정하게 되는데, IMM-PDAF는 각 모델 별로 서로 다른 PDA를 처리함으로써 동일한 목표에 대한 측정값이 모델 별로 달라지는 경우가 빈번해진다. 이것은 모델 선정에 따른 오차 값이 그대로 반영된 것으로써 각 모델 별 추정 값의 정확성을 떨어트리는 결과를 낳는다.

둘째, IMM-PDAF는 Model Estimation 단계에서 어느 모델이 선택될 확률이 높은지를 계산하기 위해서 모델 업데이트를 한다. 여기서 모든 모델들에 의해서 선택되는 모든 측정값들이 추정 값과 얼마나 관련성이 있는지를 확률적으로 계산한다. 하지만, 이러한 처리과정은 PDA과정에서 했던 것을 또 수행하는 결과를 가진다.

위의 두가지 문제를 한꺼번에 해결함은 기존의 연산량을 크게 줄이고 정확성은 IMM-PDAF와 비슷하거나 혹은 향상시킨다. 따라서 연구 목표를 다음과 같이 세가지로 표현 하겠다.

- 다중의 모델을 고려한 확률적 데이터 결합 기법을 제안함으로써 더욱 정밀한 목표의 측정값 추정이 가능하도록 한다.
- 기존 IMM-PDAF에서 수행되었던 불필요한 연산 부분을 제거 혹은 간소화 시킴으로써 연산 시간을 최적화 시킨다.

- 기존의 IMM-PDAF기법 보다 좀더 호환성 있게 하기 위해서 PDA 처리를 Filter 처리와 분리시킴으로 모델 별로 필터 적용을 서로 다르게 할 수 있도록 한다. 이러한 특성은 모델 별로 최적의 필터를 설정함으로 정확성 향상을 유도 할 수 있다.

제 2 장 PDAF를 활용한 센서 퓨전 알고리즘

2.1 센서 퓨전의 소개.

레이저, 카메라, Lidar, 레이더 등 외부 센서의 종류는 아주 다양하다. 하지만, 어느하나 완벽히 외부 환경을 인식할수 있다고 판단되는 센서는 사실상 존재하지 않는다. 그래서, 센서퓨전 시스템의 필요성이 제안되었다.

센서퓨전 시스템은 이종센서 혹은 동종센서간의 데이터를 퓨전시켜서 마치 하나의 통합된 센서를 통해서 외부 환경을 인식하도록 하는 시스템이다. 따라서, 환경변화에 따른 영향을 적게 받고 각 센서의 원리상 가지고 있던 노이즈 발생 및 부정확성에 대해서 개선된 특성을 가진다. 또한, 기존 센서들의 비주기적 측정 문제까지 해결 할 수 있다.




Figure 2-1 센서 퓨전 시스템 다이어그램.

센서퓨전 시스템은 기본적으로 Track을 통해서 관심있는 Target을 추적하게 된다. 이때, Track의 생성, 유지, 소멸을 처리하기 위해서 Figure 2-1과 같은 알고리즘 처리를 준수하게 된다. 그리고, 앞서 설명 하였듯이 센서퓨전의 주요 구성요소인 Track Management, Filter, Data Association을 Figure 2-1에서 모두 포함하고 있다.

이번 장에서는 이러한 센서퓨전 시스템의 핵심 기술이라고 할수 있는 Target Tracking Algorithm의 기존 알고리즘을 소개하고자 한다.

2.2 Interacting Multiple Model의 소개.

IMM-KF라고 부르는 Target Tracking Algorithm은 다중 프로세스 모델을 기반으로 임의의 움직임을 효과적으로 추적하기 위해서 만들어진 알고리즘이다. 기존의 필터링 기술인 Kalman Filter의 경우 Target의 Process Model을 정확히 구현해야만 하는 조건이 있다. 만약 그렇지 못한 Process Model을 사용한다면, 그만큼 오차는 크게 발생하게 된다. 하지만, 일반적으로 차량과 같이 운전자의 의지로 임의의 움직임을 가지는 Target을 예로 들어보자. 이 같은 Target의 Process Model을 정확히 표현한다는 것은 불가능하다.

그래서, 이같이 Process Model을 정확히 설정할수 없는 임의의 Target을 정확히 추적하기 위해서는 Target이 준수할 것으로 예상되는 Process Model을 여러 개 선정하고 이들 Model간 확률적 연관성 및 가능성을 표현함으로써 추적이 가능하다.[7, 8]




Figure 2-2 IMM-KF 다이어그램.

Figure 2-2와 같이 IMM-KF는 Re-Initialization, Filter Bank, Mode Estimation, Combination와 같이 4단계로 진행된다.[7, 9]

Re-Initialization은 각 모델이 반드시 일어난다란 가정하에서 바로 전단계의 모드 확률값을 이용하여 Target의 상태벡터를 재초기화 시킨다. 그래서, 각 모델별로 초기 상태값과 분산매트릭스를 구하는 단계이다. 다음 Filter Bank는 각 모델별로 구해진 초기값을 입력으로 해서 Kalman Filter를 적용하는 단계이다. Mode Estimation은 최근 측정값에 각 모델이 얼마나 근접한지를 확률적으로 표현하는 단계이다. Combination은 Filter Bank에서 구해진 각 모드별 Update 값과 Mode Estimation에서 구해진 모드별 Update 확률값을 이용하여서 평균값을 구하게 된다.

다음장에서는 IMM-KF에 대해서 자세히 소개하고자 한다.

2.3 IMM의 이론

2.3.1 기본 개념.




Figure 2-3 IMM-KF의 모식도.

- Re-initialization.

직전(k-1)의 결과값($\hat{x}_{k-1}^i$)들을 바탕으로 이번(k)번째의 i번 모델의 결과값($\hat{x}_k^i$)을 구하기 위한 초기값($\tilde{x}_{k-1}^i$)을 구하는 과정입니다. 따라서, 이것은 model을 개수만큼 반복 시행된다.

- Filter Bank.

실제 Tracking을 실시 하는 부분으로써, Kalman filter/ Particle filter/ PDAF/ JPDA등 여러가지 방법이 있다.

Re-initialization에서 구해진 mode별 초기값($\tilde{x}_{k-1}^i$)들을 바탕으로 k번째의 mode별 Updated된 결과값($\hat{x}_k^i$)들을 구하는 과정

정입니다. 이때, 반드시 mode별로 서로 다른 Processing model이 사용됩니다.

- Mode Estimation.

Filter Bank에서 구해진 mode별 결과값($\hat{x}_k^i$)들을 바탕으로 해서 k번째에서 mode별로 발생할 수 있는 확률값(μ_k^i)들을 갱신시킵니다.

- Combination.

Filter Bank에서 구해진 결과값($\hat{x}_k^i$)들과, Mode update된 결과값(μ_k^i)들을 바탕으로 통합된 1개의 결과값($\hat{x}_k$)을 도출해내는 방법으로써 Expectation과정입니다.

2.3.2 Markov Chain.

IMM-KF는 다중 모델을 사용함에 따라서 모델간 상태 변화가 얼마나 자주 일어나는지를 표기할 필요성이 발생하였다. 따라서, Markov Chain이 무엇인지 잠깐 살펴보도록 하자.




Figure 2-4 Markov Chain.

Figure 2-4와 같이 mode 'i'와 'j'가 있다고 가정하자. 이것을 Matrix로 표현하면 다음과 같다.

$$\pi = \begin{bmatrix} \pi_{ii} & \pi_{ij} \\ \pi_{ji} & \pi_{jj} \end{bmatrix} = \begin{bmatrix} 0.7 & 0.3 \\ 0.6 & 0.4 \end{bmatrix} \quad (2.1)$$

여기서 반드시 지켜져야 하는 조건은 특정 모드에서 빠져 나갈 확률의 총합은 항상 1이 되어야 한다.

2.3.3 Re-initialization.

Re-initialization 단계는 Filter Bank로 각 모델을 필터링 하기 위해서 필요한 모델별 초기값을 계산하는 단계이다.




Figure 2-5 Re-initialization Step.

Figure 2-5를 수식적으로 재표현 시키면, 평균값 정리가 된다.

$$\begin{aligned}\tilde{x}_{k-1}^j &= \sum_{i=1}^r \hat{x}_{k-1}^i \cdot \mu_{k-1}^{ij} & \because r = \text{The number of model.} \\ \tilde{\Sigma}_{k-1}^j &= \sum_{i=1}^r (\hat{\Sigma}_{k-1}^i + (\hat{x}_{k-1}^i - \tilde{x}_{k-1}^j)(\hat{x}_{k-1}^i - \tilde{x}_{k-1}^j)^\top) \cdot \mu_{k-1}^{ij}\end{aligned}\quad (2.2)$$

여기서, 주 관심사는 μ_{k-1}^{ij} 이다.

$\mu_{k-1}^{ij} = P(m_{k-1}^i | m_k^j, z_{k-1})$ 으로써 표현 할 수 있습니다.

뜻 : k-1번째에서 센서 측정을 했고, k번째에서 j model이 반드시 될 때, k-1번째에서 model이 i번째일 확률.

< proof >

$$\mu_{k-1}^{ij} = P(m_{k-1}^i | m_k^j, z_{k-1}) = \frac{P(m_k^j | m_{k-1}^i, z_{k-1}) \cdot P(m_{k-1}^i | z_{k-1})}{P(m_k^j | z_{k-1})} = \frac{\pi_{ij} \cdot \mu_{k-1}^i}{P(m_k^j | z_{k-1})} \quad (2.3)$$

$$\therefore \mu_{k-1}^{ij} = \frac{1}{\bar{C}} \pi_{ij} \cdot \mu_{k-1}^i \quad \because \bar{C} = P(m_k^j | z_{k-1}) \quad (2.4)$$

여기서, $\bar{C} = P(m_k^j | z_{k-1})$ 의 의미를 살펴보면 다음과 같다.

뜻 : k-1번째에서 센서 측정을 했다. [9]

이때, k번째에서 j번째 모델이 선택되어질 확률.

따라서, $\bar{C} = \bar{\mu}_k^j$ 인 prediction mode값이라고 생각하면 된다.

이젠, $\bar{\mu}_k^j$ 를 계산할 수 있도록 유도해 보자.

< proof >

$$\begin{aligned}
\bar{\mu}_k^j &= P(m_k^j | z_{k-1}) = \frac{P(m_k^j, z_{k-1})}{P(z_{k-1})} = \frac{\sum_{i=1}^r P(m_k^j, m_{k-1}^i, z_{k-1})}{P(z_{k-1})} \\
&= \frac{\sum_{i=1}^r P(m_k^j | m_{k-1}^i, z_{k-1}) P(m_{k-1}^i | z_{k-1}) P(z_{k-1})}{P(z_{k-1})} \\
&= \sum_{i=1}^r P(m_k^j | m_{k-1}^i, z_{k-1}) P(m_{k-1}^i | z_{k-1}) \\
&= \sum_{i=1}^r P(m_k^j | m_{k-1}^i, z_{k-1}) \mu_{k-1}^i = \sum_{i=1}^r \pi_{ij} \cdot \mu_{k-1}^i
\end{aligned} \tag{2.5}$$

구해진 Prediction Mode값까지 종합해서 Re-initialization을 정리하면 다음과 같이 수식으로 표현 가능하다.

$$\begin{aligned}
\hat{x}_{k-1}^j &= \sum_{i=1}^r \hat{x}_{k-1}^i \cdot \mu_{k-1}^{ij} & \because r = \text{The number of model} \\
\tilde{\Sigma}_{k-1}^j &= \sum_{i=1}^r (\hat{\Sigma}_{k-1}^i + (\hat{x}_{k-1}^i - \hat{x}_{k-1}^j)(\hat{x}_{k-1}^i - \hat{x}_{k-1}^j)^\top) \cdot \mu_{k-1}^{ij} \\
\mu_{k-1}^{ij} &= \frac{\pi_{ij} \cdot \mu_{k-1}^i}{\sum_{i=1}^r \pi_{ij} \mu_{k-1}^i}
\end{aligned}$$

(2.6)

2.3.4 Filter Bank Step.

Filter Bank단계는 Re-initialization으로 구해진 초기값을 바탕으로 k번째의 Target의 상태벡터를 각 모드별로 구해내는 단계이다.




Figure 2-6 Filter Bank Step.

Figure 2-6은 3개의 모델을 적용한 Filter Bank의 모습이다.

이때 사용되는 필터를 Kalman Filter라고 가정하자. 그럼, 각 모델별로 다음과 같은 과정을 반복적으로 거치게 된다.

< System Modeling >

$$\mathbf{x}_{k+1} = \Phi_k \mathbf{x}_k + \mathbf{B}_k \omega_k \quad (2.7)$$

$$\mathbf{z}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k \quad (2.8)$$

IMM-KF는 다중 모델 모델링을 통하여서 추적한다고 앞에서 언급했다. System Modeling이 다중 모델 선정의 단계를 나타낸다. 따라서, 여기서 Process modeling 및 Sensor modeling을 한다.

< Prediction >

$$\bar{\mathbf{x}}_k = \Phi_{k-1} \hat{\mathbf{x}}_{k-1} \quad (2.9)$$

$$\bar{\Sigma}_k = \Phi_{k-1} \tilde{\Sigma}_{k-1} \Phi_{k-1}^T + \mathbf{Q}_{k-1} \quad \because \mathbf{Q}_{k-1} = \mathbf{E}[\mathbf{B}_{k-1} \omega_{k-1} \omega_{k-1}^T \mathbf{B}_{k-1}^T] \quad (2.10)$$

Prediction 단계에서는 Re-initialization에서 구해진 초기값을 바탕으로 모델링된 System이 예측하는 Target의 상태벡터를 구한다.

< Correction >

$$\hat{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \mathbf{L}_k (\mathbf{z}_k - \mathbf{C}_k \bar{\mathbf{x}}_k) \quad (2.11)$$

$$\mathbf{L}_k = \bar{\Sigma}_k \mathbf{C}_k^T (\mathbf{C}_k \bar{\Sigma}_k \mathbf{C}_k^T + \mathbf{R}_k)^{-1} \quad \because \mathbf{R}_k = \mathbf{E}[\mathbf{v}_k \mathbf{v}_k^T] \quad (2.12)$$

$$\Sigma_k = (\mathbf{I} - \mathbf{L}_k \mathbf{C}_k) \bar{\Sigma}_k \quad (2.13)$$

Correction 단계에서는 측정값을 바탕으로 Prediction값에 존재할 system noise를 줄여서 좀더 정확한 Target의 상태벡터를 구한다.[10]

2.3.5 Mode Estimation Step.

Mode Update란 Re-initialization단계와 Combination 단계에서 항상 필요로 하는 값인 μ_k^i 값을 이번의 결과 값들($\mathbf{x}_k^i, \bar{\Sigma}_k^i$)을 통해서 갱신하는 것이 목표입니다.




Figure 2-7 Mode Estimation Step.

Mode Estimation단계에서 μ_k^i 값을 구하기 위해서 먼저 해석적 특성을 알아보고 이를 바탕으로 수식을 유도해 보고자 한다.

< 해석적 풀이 >

$\mu_k^i = P(m_k^i | z_k)$ 로 표현 할 수 있다. k번째 센서 측정을 실시 했을 때, 결과값이 i번째 model이 선택될 확률을 나타낸다.

이것을 바꾸어서 해석해 보면 다음과 같습니다. k번째에 센서로 측정한 값이 k번째 model i의 Filter prediction 결과 값($\bar{x}_k^i$)에서 떨어진 정도에 반비례 하여서 i번째 model이 선택될 확률이 높아진다. 따라서, 센서확률 $\Lambda_k^i(z_k) = N(z_k; \bar{z}_k^i, (z_k - \bar{z}_k^i)(z_k - \bar{z}_k^i)^T)$ 를 우선적으로 구해보자.

< Proof >

$$P(z_k | m_k^i, z_{k-1}) = \Lambda_k^i(z_k) = N(z_k; \bar{z}_k^i, (z_k - \bar{z}_k^i)(z_k - \bar{z}_k^i)^T) \quad (2.14)$$

$$\because z_k = C \cdot x_k + v_k, \quad \bar{z}_k^i = C \cdot \bar{x}_k^i$$

$$\begin{aligned} \Lambda_k^i(z_k) &= N(z_k; \bar{z}_k^i, E[(z_k - \bar{z}_k^i)(z_k - \bar{z}_k^i)^T]) \\ &= N(z_k; C \cdot \bar{x}_k^i, E[(C \cdot x_k + v_k - C \cdot \bar{x}_k^i)(C \cdot x_k + v_k - C \cdot \bar{x}_k^i)^T]) \\ &= N(z_k; C \cdot \bar{x}_k^i, E[(C \cdot (x_k - \bar{x}_k^i) + v_k)((x_k - \bar{x}_k^i)^T \cdot C^T + v_k^T)]) \\ &= N(z_k; C \cdot \bar{x}_k^i, E[C \cdot (x_k - \bar{x}_k^i) \cdot (x_k - \bar{x}_k^i)^T \cdot C^T + C \cdot (x_k - \bar{x}_k^i) \cdot v_k^T + v_k \cdot (x_k - \bar{x}_k^i)^T \cdot C^T + v_k v_k^T]) \\ &= N(z_k; C \cdot \bar{x}_k^i, C \cdot E[\bar{e}_k^i \cdot \bar{e}_k^{iT}] \cdot C^T + C \cdot E[\bar{e}_k^i \cdot v_k^T] + E[v_k \cdot \bar{e}_k^{iT}] \cdot C^T + E[v_k v_k^T]) \end{aligned} \quad (2.15)$$

$\bar{e}_k^i, v_k$ 는 서로 un-correlation하다. 즉 $E[\bar{e}_k^i \cdot v_k^T] = E[v_k \cdot \bar{e}_k^{iT}] = 0$ 이 된다. 이것을 정리하면 다음과 같다.

$$\begin{aligned} \Lambda_k^i(z_k) &= N(z_k; C \cdot \bar{x}_k^i, C \cdot \bar{\Sigma}_k^i \cdot C^T + R_k) \because \bar{e}_k^i = z_k - C \cdot \bar{x}_k^i \\ &= \frac{1}{\sqrt{(2\pi)^d \det(S_k^i)}} e^{-\frac{1}{2} \bar{e}_k^{iT} (S_k^i)^{-1} \bar{e}_k^i} \quad \because S_k^i = C \cdot \bar{\Sigma}_k^i \cdot C^T + R_k \end{aligned} \quad (2.16)$$

< 해석적 정리 >

$\Lambda_k^i(z_k) = P(z_k | m_k^i, z_{k-1})$ 값을 구했으므로 μ_k^j 를 $\Lambda_k^i(z_k)$ 에 관해
서 어떤 관계를 가지고 있는지 유도해보자.

< Proof >

$$\begin{aligned}
 \mu_k^j &= P(m_k^j | z_k) = \frac{P(m_k^j, z_k) \cdot P(z_{k-1})}{P(z_k) \cdot P(z_{k-1})} = \frac{P(m_k^j, z_k, z_{k-1})}{P(z_k, z_{k-1})} = \frac{P(z_k, m_k^j, z_{k-1})}{\sum_{i=1}^r P(z_k, m_k^i, z_{k-1})} \\
 &= \frac{P(z_k | m_k^j, z_{k-1}) P(m_k^j | z_{k-1}) P(z_{k-1})}{\sum_{i=1}^r P(z_k | m_k^i, z_{k-1}) P(m_k^i | z_{k-1}) P(z_{k-1})} = \frac{P(z_k | m_k^j, z_{k-1}) P(m_k^j | z_{k-1})}{\sum_{i=1}^r P(z_k | m_k^i, z_{k-1}) P(m_k^i | z_{k-1})} \\
 &= \frac{P(z_k | m_k^j, z_{k-1}) \cdot \bar{\mu}_k^j}{\sum_{i=1}^r P(z_k | m_k^i, z_{k-1}) \cdot \bar{\mu}_k^i} = \frac{\Lambda_k^j(z_k) \cdot \bar{\mu}_k^j}{\sum_{i=1}^r \Lambda_k^i(z_k) \cdot \bar{\mu}_k^i} = \frac{\Lambda_k^j(z_k) \cdot \sum_{i=1}^r \pi_{ij} \mu_{k-1}^i}{\sum_{i=1}^r \left(\Lambda_k^i(z_k) \cdot \sum_{n=1}^r \pi_{ni} \mu_{k-1}^n \right)}
 \end{aligned}
 \tag{2.17}$$

$$\boxed{\mu_k^j = \frac{\Lambda_k^j(z_k) \cdot \sum_{i=1}^r \pi_{ij} \mu_{k-1}^i}{\sum_{i=1}^r \left(\Lambda_k^i(z_k) \cdot \sum_{n=1}^r \pi_{ni} \mu_{k-1}^n \right)}} \tag{2.18}$$

위 수식이 성립하기 위한 조건은 다음과 같습니다.

- $P(z_k), P(z_{k-1})$ 사이가 서로 Independence 하여야 합니다.
- $P(m_k^i), P(z_{k-1})$ 사이가 서로 Independence 하여야 합니다.
- $\sum_{i=1}^r P(m_k^i) = 1 \quad \because r = \text{The number of model}$

위에서 언급한 조건들은 모든 상황에서 거의 지켜지는 일반적인 조건이므로 System 설계시에 간과하여도 무방 할 것으로 여겨진다.

2.3.6 Combination Step.

여기서는 최종 Output 값($\hat{x}_k, \hat{\Sigma}_k$)을 출력하기 위해서 각 model 별 출력값들($\hat{x}_k^i, \hat{\Sigma}_k^i$)를 이용합니다. 계산 방법은 일반적으로 평균 계산결과를 출력으로 한다.[7, 8, 11, 12]




Figure 2-8 Combination Step.

여기서는 일반적 해법을 기준으로 다음과 같이 수식화 한다.

$$\begin{aligned} \hat{x}_k &= E[\hat{x}_k^i] = \sum_{i=1}^r \hat{x}_k^i \cdot \mu_k^i \\ \hat{\Sigma}_k &= \text{Cov}[\hat{x}_k^i] = \sum_{i=1}^r \left(\left(\hat{\Sigma}_k^i + (\hat{x}_k^i - \hat{x}_k)(\hat{x}_k^i - \hat{x}_k)^T \right) \cdot \mu_k^i \right) \end{aligned} \quad (2.19)$$

이렇게 해서 구해진 State Vector는 실제 Target의 현재 상태로 사용하게 된다. 지금까지, 임의의 움직임을 효과적으로 추적하는 대표적인 Tracking Algorithm으로 IMM-KF를 소개하였습니다.

하지만, IMM-KF는 단일 Target만을 추적할수 있다. 그래서, 다중 Target을 추적하는 해법으로 그 시각을 넓히고자 다음장에서는 PDAF에 대해서 소개하고자 한다.[1, 11]

2.4 Probabilistic Data Association Filter의 소개

본 논문에서는 다중 Target을 추적하기 위한 해법으로 JPDAF, HMT, GPB, IMM-PDAF방법들 중에서 IMM-PDAF를 선택하였다. 이유는 다른 여타의 해법들과 비교하여서 연산량 측면에서 우수한 성능을 보이고 또한, 정확성 측면에서 다른 해법에 비해 다소 떨어지지만, 충분히 신뢰성 있는 결과를 보이고 있으므로 IMM-PDAF 방식이 상황인식을 실시간으로 처리해야 하는 현실적 조건에서 가장 적합하다고 판단했다. 다음은, PDAF의 주요 특성이다.




Figure 2-9 IMM-PDAF의 다이어그램.

- 관심표적의 측정값을 다수의 측정값들 중에서 찾는다.
- 센서의 간헐적 표적측정실패에 대해서 융통성있게 대처한다.
- 확률기반 추적 알고리즘으로써 그 신뢰성을 보장받을수 있다.

이러한 특성들을 바탕으로 본 장에서는 Figure 2-9와 같이 IMM-PDAF에서 Filter Bank 부분을 담당하는 PDAF에 대해서 자세히 기술하고자 한다.

2.5 PDAF의 이론.

2.5.1 기본 개념.




Figure 2-10 PDAF의 알고리즘 모식도.

PDAF는 처리단계를 명확히 구분하기 힘들다. 이유는 수식적으로 Kalman Filter 이론과 PDA이론을 화합시킨 형태이기 때문이다.

하지만, 설명을 하기 위해서 편의상 Figure 2-10을 참고로 Prediction, Gating, Calculation Conditional Probability, Innovation Vector, Update등 총 5단계로 구분하고자 한다.

– Prediction Step

Prediction 단계는 Kalman의 Prediction 원리를 준수한다.

따라서, 이것은 다시 Process Prediction과 Measurement Prediction 단계로 분류 할 수 있다.

< Process Prediction >

Process Prediction은 Target의 운동특성을 Modeling한 Process Model과 과거의 Target의 상태정보를 이용하여서 현재의 Target 상태 및 오차범위를 예측하기 위한 단계이다.




Figure 2-11 Process Prediction 다이어그램.

Figure 2-11에서 $k-1$ 번째 Target의 상태 벡터가 화살표 방향으로 이동한 것을 볼 수 있다. 이때의 이동을 위한 특성을 Process Model로 표현한 것이고, 이것을 다음과 같이 수식화 한다.

$$\bar{\mathbf{x}}_k = \Phi_{k-1} \hat{\mathbf{x}}_{k-1} \quad (2.20)$$

$$\bar{\Sigma}_k = \Phi_{k-1} \Sigma_{k-1} \Phi_{k-1}^T + Q_{k-1} \quad \because Q_{k-1} = \mathbf{E}[\mathbf{B}_{k-1} \omega_{k-1} \omega_{k-1}^T \mathbf{B}_{k-1}^T] \quad (2.21)$$

< Measurement Prediction >

Measurement Prediction은 예측된 현재의 Target 상태정보와 Sensor의 측정 특성을 표현한 Sensor Model을 바탕으로 현재의 측정값 및 오차범위를 예측하는 단계이다.



Figure 2-12 Measurement Prediction 다이어그램.

Figure 2-12를 보면, Process Prediction으로 구해진 k번째 Target의 예상 벡터가 Sensor Model에 의해서 이동 및 분산이 변화한 것을 확인 할 수 있다. 이러한을 수식으로 표현하면 다음과 같이 표현 가능하다.

$$\mathbf{z}_k = \mathbf{C}_k \mathbf{x}_k \quad (2.22)$$

$$\bar{\mathbf{S}}_k = \mathbf{C}_k \bar{\Sigma}_k \mathbf{C}_k^T + \mathbf{R}_k \quad \because \mathbf{R}_k = \mathbf{E}[\mathbf{v}_k \mathbf{v}_k^T] \quad (2.23)$$

여기서 $\bar{\mathbf{S}}_k$ 는 Innovation Variance Matrix라고 부른다.

– Gating Step

Gating은 Prediction단계로 얻은 예상측정값 및 오차범위를 이용하여서 주위에 존재하는 다수의 실제 측정값들 중 관심Target의 측정값이 될수있는 후보군을 선별하는 단계이다.

Figure 2-10의 Gating을 보면 유효영역(Validation Gate)안의 측정값만을 인정하고 나머지 측정값은 무시하는 것을 볼 수 있다.

– Calculation Conditional Probability Step

Calculation Conditional Probability는 선택받은 실제 측정값이 예상 측정값 상태와 얼마나 유사한지를 각 측정값별로 계산하는 단계이다. 이것은 Innovation Vector단계에서 확률적으로 가장 신뢰할수 있는 측정값을 추정하기 위해서 반드시 필요한 단계이다.

– Innovation Vector Step

Innovation Vector는 Calculation Conditional Probability 단계로 얻은 각 측정값별 신뢰도값을 이용하여서 Gating된 측정값들을 평균값을 구하게 된다. 그래서, 이것과 예상측정값과의 격차를 계산하면 Innovation Vector를 구할수 있다.

Innovation Vector는 Update단계에서 Kalman Update를 하기 위해서 반드시 필요한 값이다.

– Update Step

Update는 Kalman Filter의 Update단계를 준수한다.

그리고, Innovation Vector로 인해서 발생된 측정값의 불확실성도 준수한다.

Update는 이 두가지 문제를 바탕으로 k번째 Target의 상태 벡터를 구하기 위해서 새롭게 유도된 수식을 이용하게 된다.

지금까지 PDAF의 각 단계별 알고리즘을 간략히 살펴보았다. 앞에서 설명한 Prediction단계의 설명은 충분히 표현되었다고 간주하고, 다음장부터 Gating, Calculation Conditional Probability, Innovation Vector, Update등을 설명하고자 한다.

2.5.2 Clutter.

PDAF이론에서 Clutter란 용어가 등장한다.

Clutter란 지형, 지물, 동.식물, 안개, 비, 눈 등에 의해서 생기는 측정대상으로써, 일반적으로 Target이 아닌 대상이 측정 되었을때, 이 측정값을 나타낸다. 이러한 현상이 가장 빈번하게 나타나는 센서로는 레이다가 있겠다.[13]




Figure 2-13 레이다에 잡힌 clutter의 예.

Figure 2-13은 이러한 Clutter의 예로써 날씨와 지형이 원인임을 보여주고 있다.

Clutter에 대해서 잘못된 상식이 한가지 있다. 그것은 Noise이다. Clutter는 Noise가 아니다. 그리고 Noise는 Clutter가 될 수 없다. Clutter는 지형, 지물과 같이 외부 대상들에 의해서 나타나는 방해 요소이고, Noise는 센서 하드웨어의 구조 및 민감성에 의해서 발생한 내부적 요인으로 발생한 방해요소이다.[1, 13]

정리하면, "Inference=Clutter(external) + Noise(internal)"라고 인식하면 되겠다.

PDAF에서는 이런 Clutter를 어떻게 사용하고 있을까요? 이에 대한 답을 PDAF가 가지는 전제 조건으로 하겠습니다.[1, 13, 14]

- 센서가 Target을 항시 측정하는 것은 아니다. 따라서, PDAF는 센서가 Target을 측정할 확률을 알고 있다고 가정한다. 우린 이것을 POD(Probability of Detection)이라고 명명한다.
- Clutter가 발생하는 위치와 빈도는 POD와 서로 독립적이다.
- Clutter는 항시 포아송 확률로 발생한다고 가정한다.
- 발생한 Clutter영역은 PDAF의 유효영역(Validation Gate)에서는 항시 Uniform Distribution한 분포를 가진다고 가정한다.
- Target의 크기는 Sensor Model의 오차범위보다 충분히 커서 Target들의 측정값이 겹쳐서 발생하지 않는다.

위 전제조건을 통해서 알 수 있듯이 모든 Target 측정시 Clutter가 발생할 염려까지도 고려해서 개발된 알고리즘임을 알 수 있다.

그럼, Clutter의 수학적 표현 및 측정방법을 알아보자.

$$\lambda_k = (m_k - 1) / \text{Volume} \quad (2.24)$$

$$\text{Volume} = c \cdot |\bar{\mathbf{S}}_k|^{1/2} \cdot G^{n/2} \quad \because n = \text{DOF} \quad (2.25)$$

λ_k : 단위 부피당 존재하는 Clutter의 개수. (Clutter밀도)

가정 : 측정값들 중 Target의 측정값은 반드시 1개이다.

Volume : n차원의 유효영역 (Validation Gate)의 부피.

m_k : 유효영역 (VG)안에 있는 실제 측정값 개수.

n : Clutter개념을 적용하고자 하는 차원수.

G : Innovation Mahalanobis distance.

$|\bar{\mathbf{S}}_k|$: Innovation Variance Matrix의 Determinant값.

c : 차원별로 서로 다른 상수값을 가진다.

Table 2-1 차원수별 상수 c 의 값.

	$n=1$	$n=2$	$n=3$
c	2	π	$\frac{4}{3}\pi$

< 참고 : Innovation Mahalanobis distance. >

수식적으로 표현하면 다음과 같다.

$$M_k = (\mathbf{z}_k - \bar{\mathbf{z}}_k)^T \cdot \bar{\mathbf{S}}_k^{-1} \cdot (\mathbf{z}_k - \bar{\mathbf{z}}_k) \quad (2.26)$$

Mahalanobis distance는 확률적으로 Variance값을 기준으로 놓고 특정 확률 지점이 Variance의 몇 배수 위치에 있는지를 표현해주는 상대거리적인 성격을 가진다.

2.5.3 Gating Step.

Gating은 예상측정값으로부터 일정크기의 유효영역을 설정하여서 유효영역안의 모든 측정값들을 Target의 유효 측정값들로 선택하는 알고리즘이다. 이러한, 표현을 그림으로 하면 Figure 2-14와 같다.




Figure 2-14 Gating 전과 후의 모습.

그럼, 어떻게 해서 Gating을 하는지 방법을 알아보겠다. Gating 알고리즘의 핵심은 Mahalanobis distance에 있다.

$$(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T \cdot \bar{\mathbf{S}}_k^{-1} \cdot (\mathbf{z}_k - \bar{\mathbf{z}}_k) \leq G \quad (2.27)$$

위 수식은 유효거리 G 를 설정하였을 때, Gating을 수식으로 표현한 것이다. 이와 같이 특정 측정값의 Mahalanobis distance값이 유효영역까지의 거리 G 보다 작거나 같으면, 이때의 측정값은 Gating을 통과한 유효 측정값이 된다.

그럼, G 값은 어떻게 설정 할 수 있을까? G 를 설정하기 위해서 우린 chi-table을 참조하면 된다. 이때 필요한 입력값 2개가 있다.[9]

- Mahalanobis distance에 적용된 측정값 Vector의 차원수.
- Target의 실제 측정값이 유효영역에 없을 확률.(1- P_G)

여기서 2번째 입력값을 계산하기 위해서 P_G 를 구해야 한다. 이것은 예측 측정값을 중심으로 존재 확률이 Gaussian 분포를 가진다고 가정하였을 때, 그 넓이가 즉 P_G 가 된다.[15]

2.5.4 Calculation Conditional Probability Step.

Calculation Conditional Probability는 예상 측정값을 기준으로 Gating된 실제 측정값들 각각이 Target의 측정값이 될 가능성을 확률적으로 표현하는 단계이다. 이때, Gating안의 측정값들이 Clutter일 가능성까지도 고려해서 계산된다.




Figure 2-15 Calculation Conditional Probability.

Figure 2-15의 화살표는 앞에서 설명한 확률적 표현값을 나타낸다고 생각하면, 이해가 쉬울 것이다.

그럼, 이제 확률적 표현 방법에 대해서 탐구해 보자.

먼저, 이번 단계를 위해서 우리가 구하고자 하는 확률을 정의해 보자.

< 해석적 접근 >

우선 실제 센서값들이 주어지므로 k 번째 측정까지 했음을 알 수 있다. 그리고, Target의 측정값이 유효영역 안에 있을지 밖에 있을지는 모르나 좌우지간 Target의 측정값이 측정되었다고 가정해 보자. 그럼, 이때 유효영역 안에 존재하는 측정값 각각이 얼마의 확률을 가지는지 알아내야 한다. 바로 이것이 우리가 구하고자 하는 확률값의 정의가 된다.

이것을 수식으로 표현하면 다음과 같다.

$$p_{k,j} = P(T_{k,j} | z_{k,g}, Z_k) \quad (2.28)$$

- Z_k : k 번째까지 측정한 측정값들의 그룹을 뜻한다.
- $z_{k,g}$: k 번째에 Gating을 통과한 측정값의 그룹을 뜻한다.
- $T_{k,j}$: k 번째에 Gating을 통과한 측정값 중 j 번째 측정값이 Target의 측정값일 가능성을 뜻한다.

위 식을 바탕으로 우리가 계산 할 수 있는 요소들의 구성으로 표현을 바꾸어보자.

$$\begin{aligned} p_{k,j} &= P(T_{k,j} | z_{k,g}, Z_k) = \frac{P(z_{k,g}, T_{k,j}, Z_k)}{P(z_{k,g}, Z_k)} \\ &= \frac{P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j}, Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g}, T_{k,j}, Z_k)} = \frac{P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j}, Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j}, Z_k)} \quad (2.29) \\ &= \frac{P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)P(Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)P(Z_k)} \end{aligned}$$

유도한 내용을 정리하면, 다음과 같다.

$$p_{k,j} = \frac{P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)} \quad (2.30)$$

그럼, 이제 준비는 완료되었다. 식(2.30)에 따르면, 두가지 확률값만 계산 할 수 있으면 된다. 이제 각 요소별로 유도해 보자.

< $j \neq 0, P(T_{k,j} | Z_k)$ 유도. >

의미 : k번째까지 측정했을 때, Gating을 통과한 측정값들 중 j번째 측정값이 Target의 측정값이 될 확률을 뜻한다.

풀이 : 일단 Target의 측정값이 존재해야 한다면 조건이 있다.

따라서, 앞에서 언급한 POD(Probability of Detection)이

필요함을 알 수 있다. 우린 POD를 P_D 라고 표기하자.

다음, Gating을 통과한 측정값 중 어느 하나 이므로

Target의 측정값이 측정되었다면, 반드시 Gating안에

있어야 한다면 조건이 있다. 따라서, 2.5.3절에서 소개한

P_G 가 필요하다.

위 풀이를 수식으로 표현하면 다음과 같다.

$$j \neq 0, P(T_{k,j} | Z_k) = P_D P_G \quad (2.31)$$

< $j = 0, P(T_{k,j} | Z_k)$ 유도. >

의미 : k번째까지 측정했을 때, Gating을 통과한 측정값들 중 어느 측정값도 Target의 측정값이 아닐 확률을 뜻한다.

풀이 : Target의 측정이 안된 경우도 이 경우에 해당한다.

Target을 측정 했지만, Gating을 통과 못했을수 있다.

따라서, 식(2.31)의 경우 이외의 모든 경우가 해당한다.

위 풀이를 수식으로 표현하면 다음과 같다.

$$j = 0, P(T_{k,j} | Z_k) = 1 - P_D P_G \quad (2.32)$$

< $j \neq 0, P(z_{k,g} | T_{k,j}, Z_k)$ 유도. >

의미 : k번째까지 측정했고, Gating을 통과한 측정값들 중 j번째 측정값이 Target의 측정값이라고 했을 때, Gating을 통과한 측정값들의 그룹확률을 뜻한다.

풀이 : 우선, PDAF의 가정을 떠올려 보자. Gating을 통과한

측정값들 중에서는 현재 찾고자하는 Target 이외의 Target의 측정값은 존재하지 않는다. 이것은 바꾸어 말하면, Gating을 통과한 측정값들은 모두 Clutter이거나 혹은 Target의 측정값을 포함한 Clutter들이란 뜻을 가진다.

위 풀이를 수식으로 표현하면 다음과 같다.

$$j \neq 0, P(z_{k,g} | T_{k,j}, Z_k) = \lambda^{(m_k-1)} \cdot \frac{N(z_{k,j}; \bar{z}_k, S_k)}{P_G} \quad (2.33)$$

- 가정 : Gating을 통과한 측정값들 중에는 다른 Target의 측정값이 포함되지 않는다.

- 가정 : Target의 측정값이 아닌 것은 모두 Clutter이고,
유효범위 내부에서는 Uniform Distribution한
분포를 가진다.

< $j = 0, P(z_{k,g} | T_{k,j}, Z_k)$ 유도. >

의미 : k번째까지 측정했고, Gating을 통과한 측정값들 중 어느
측정값도 Target의 측정값이 될 수 없을때, Gating을 통과
한 측정값들의 그룹확률을 뜻한다.

풀이 : 식(2.33)에 적용된 가정은 여기서도 동일하게 적용된다.
그러므로, Gating을 통과한 모든 측정값은 Clutter가 됨을
알 수 있다.

위 풀이를 수식으로 표현하면 다음과 같다.

$$j = 0, P(z_{k,g} | T_{k,j}, Z_k) = \lambda^{(m_k)} \quad (2.34)$$

지금까지 식(2.30)의 구성요소를 풀어 보았다.

이제 각 풀이를 식(2.30)에 적용하여서 답을 유도해 보자.

< $j \neq 0$, $p_{k,j}$ 의 값은? >

의미 : j번째 측정값이 Target의 측정값일 객관적인 확률.

$$\begin{aligned}
 p_{k,j} &= \frac{P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)} \\
 &= \frac{\lambda^{(m_k-1)} \cdot \frac{N(z_{k,j}; \bar{z}_k, S_k)}{P_G} \cdot P_D \cdot P_G}{\left(\sum_{j=1}^{m_k} \lambda^{(m_k-1)} \cdot \frac{N(z_{k,j}; \bar{z}_k, S_k)}{P_G} \cdot P_D \cdot P_G \right) + \lambda^{(m_k)} \cdot (1 - P_D \cdot P_G)} \quad (2.35) \\
 &= \frac{N(z_{k,j}; \bar{z}_k, S_k)}{\left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k, S_k) \right) + \lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D}}
 \end{aligned}$$

위 식을 정리해서 풀면 다음과 같다.

$$p_{k,j} = \frac{e^{-\frac{1}{2}(z_{k,j} - \bar{z}_k)^T S_k^{-1} (z_{k,j} - \bar{z}_k)}}{\left(\sum_{j=1}^{m_k} e^{-\frac{1}{2}(z_{k,j} - \bar{z}_k)^T S_k^{-1} (z_{k,j} - \bar{z}_k)} \right) + \lambda \cdot \sqrt{\det(2\Pi S_k)} \cdot \frac{(1 - P_D \cdot P_G)}{P_D}} \quad (2.36)$$

< j=0, p_{k,j}의 값은? >

의미 : 어느 측정값도 Target의 측정값이 아닐 확률.

$$\begin{aligned}
 p_{k,0} &= \frac{P(z_{k,g} | T_{k,0}, Z_k)P(T_{k,0} | Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)} \\
 &= \frac{\lambda^{(m_k)} \cdot (1 - P_D \cdot P_G)}{\left(\sum_{j=1}^{m_k} \lambda^{(m_k-1)} \cdot \frac{N(z_{k,j}; \bar{z}_k, S_k)}{P_G} \cdot P_D \cdot P_G \right) + \lambda^{(m_k)} \cdot (1 - P_D \cdot P_G)} \quad (2.37) \\
 &= \frac{\lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D}}{\left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k, S_k) \right) + \lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D}}
 \end{aligned}$$

위 식을 정리해서 풀면 다음과 같다.

$$p_{k,0} = \frac{\lambda \cdot \sqrt{\det(2\Pi S_k)} \cdot \frac{(1 - P_D \cdot P_G)}{P_D}}{\left(\sum_{j=1}^{m_k} e^{-\frac{1}{2}(z_{k,j} - \bar{z}_k)^T S_k^{-1} (z_{k,j} - \bar{z}_k)} \right) + \lambda \cdot \sqrt{\det(2\Pi S_k)} \cdot \frac{(1 - P_D \cdot P_G)}{P_D}} \quad (2.38)$$

이렇게 구해진 확률 값인 식(2.36)과 식(2.38)을 Conditional Probability라고 부른다. Conditional Probability는 다음 단계인 Innovation Vector에서 보다 정확한 Innovation값을 구하고 또한 Innovation으로 발생 될 수 있는 불확실성을 Variance Matrix로 구하기 위해서 사용이 된다. [10, 12, 16]

2.5.5 Innovation Vector Step.

Innovation Vector에서는 측정값과 Conditional Probability값을 이용하여서 Innovation의 평균값을 구한다. 그러면, Innovation은 무엇일까?

$$\mathbf{z}_k - \bar{\mathbf{z}}_k \approx \mathbf{v}_k = \sum_{j=1}^{m_k} \mathbf{p}_{k,j} (\mathbf{z}_{k,j} - \bar{\mathbf{z}}_k) \quad (2.39)$$

식(2.39)에서 $(\mathbf{z}_{k,j} - \bar{\mathbf{z}}_k)$ 을 우린 Innovation이라고 부른다. 즉 실제 측정값이 예상측정값으로부터 얼마만큼 차이를 가지고 있는지를 수치적으로 표현한 것을 Innovation Vector라고 부른다.




Figure 2-16 Innovation Vector의 평균을 구한 모습.

식(2.39)는 Gating을 통과한 실제 측정값들 각각의 Innovation Vector를 구하고 각 측정값의 Conditional Probability값을 곱하는 방식으로 가장 신뢰 할 수 있는 Innovation값을 찾게 된다.

Figure 2-16은 이러한 과정을 도식화한 것이다.

2.5.6 Update Step.

Update단계에서는 지금까지 얻은 Innovation, Conditional probability, Prediction State Vector 그리고 Kalman Gain을 이용하여 Updated State Vector와 Updated Variance Matrix값을 구한다. 이때, 중요한것은 Kalman Filter 법칙을 준수한다는 것이다.

잠깐, Kalman Filter를 정리해 보자.

만약, 시스템을 다음과 같이 Modeling 하였다고 하자.

$$\begin{cases} \mathbf{x}_{k+1} = \Phi \mathbf{x}_k + \mathbf{B} \omega_k \\ \mathbf{z}_k = \mathbf{C} \mathbf{x}_k + \mathbf{v}_k \end{cases} \quad (2.40)$$

식 (2.40)에 따라서, Kalman Gain을 구하는 식은 다음과 같다.

$$\mathbf{L}_k = \bar{\Sigma}_k \mathbf{C}^T (\mathbf{C} \bar{\Sigma}_k \mathbf{C}^T + \mathbf{R}_k)^{-1} \quad \because \mathbf{R}_k = \mathbf{E}[\mathbf{v}_k \mathbf{v}_k^T] \quad (2.41)$$

이렇게 구해진 Kalman Gain을 이용해서 Updated State Vector와 그것의 Variance Matrix를 구할수 있다.

$$\hat{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \mathbf{L}_k (\mathbf{z}_k - \mathbf{C} \bar{\mathbf{x}}_k) \quad (2.42)$$

$$\Sigma_k = (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k \quad (2.43)$$

이러한 Kalman Filter의 성질을 기억하고 Updated State Vector와 이것의 Variance Matrix의 유도를 시작해 보자.

< Updated State Vector 유도. >

식 (2.42)를 이용하자. 이때, 식 (2.39)에서 $(\mathbf{z}_k - \bar{\mathbf{z}}_k \approx \nabla_k)$ 라고 했으므로 다음과 같이 다시 정의 할 수 있다.

$$\hat{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \mathbf{L}_k(\mathbf{z}_k - \mathbf{C}\bar{\mathbf{x}}_k) \approx \bar{\mathbf{x}}_k + \mathbf{L}_k\mathbf{v}_k \quad (2.44)$$

식(2.44)를 정리하면 Updated State Vector는 다음과 같다.

$$\boxed{\hat{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \mathbf{L}_k\mathbf{v}_k} \quad (2.45)$$

< Updated Variance Matrix 유도. >

Variance는 State Vector로부터 얼마만큼의 오차를 가지고 분포 분포할 것 그 평균치를 제공한 값을 Matrix로 표현한 것이다.

이것을 수식으로 표현하면 다음과 같다.

$$\Sigma_k = \mathbf{E}[\mathbf{e}_k \mathbf{e}_k^T] = \mathbf{E}[(\mathbf{x}_k - \hat{\mathbf{x}}_k)(\mathbf{x}_k - \hat{\mathbf{x}}_k)^T] \quad (2.46)$$

우린 Σ_k 를 $\bar{\Sigma}_k$ 로 이루어진 식으로 재표현 해야만 한다. 따라서, $\hat{\mathbf{x}}_k$ 를 다음과 같이 재표현 해보자. 이때, $\mathbf{z}_{k,j} = \mathbf{C}\mathbf{x}_k + \hat{\mathbf{v}}_{k,j}$ 로 표현할 수 있음을 기억하자.

$$\begin{aligned} \hat{\mathbf{x}}_k &= \bar{\mathbf{x}}_k + \mathbf{L}_k \sum_{j=1}^{m_k} (p_{k,j}(\mathbf{z}_{k,j} - \mathbf{C}\bar{\mathbf{x}}_k)) = (\mathbf{I} - \mathbf{L}_k \mathbf{C} \sum_{j=1}^{m_k} p_{k,j}) \bar{\mathbf{x}}_k + \mathbf{L}_k \sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j} \\ &= ((\sum_{j=1}^{m_k} p_{k,j} + p_{k,0})\mathbf{I} - \mathbf{L}_k \mathbf{C} \sum_{j=1}^{m_k} p_{k,j}) \bar{\mathbf{x}}_k + \mathbf{L}_k \sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j} \\ &= p_{k,0} \bar{\mathbf{x}}_k + (1 - p_{k,0})(\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\mathbf{x}}_k + \mathbf{L}_k \sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j} \\ &= p_{k,0} \bar{\mathbf{x}}_k + (1 - p_{k,0})(\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\mathbf{x}}_k + \mathbf{L}_k \mathbf{C} \bar{\mathbf{x}}_k \sum_{j=1}^{m_k} p_{k,j} + \mathbf{L}_k \sum_{j=1}^{m_k} (p_{k,j} \hat{\mathbf{v}}_{k,j}) \end{aligned} \quad (2.47)$$

식 (2.47) 을 바탕으로 Updated Error (e_k) 를 재 표현 해보자.

$$\begin{aligned}
e_k &= x_k - \hat{x}_k \\
&= x_k - p_{k,0} \bar{x}_k - (1 - p_{k,0})(I - L_k C) \bar{x}_k - L_k C x_k \sum_{j=1}^{m_k} p_{k,j} - L_k \sum_{j=1}^{m_k} (p_{k,j} \hat{v}_{k,j}) \\
&= (I - L_k C \sum_{j=1}^{m_k} p_{k,j}) x_k - p_{k,0} \bar{x}_k - (1 - p_{k,0})(I - L_k C) \bar{x}_k - L_k \sum_{j=1}^{m_k} (p_{k,j} \hat{v}_{k,j}) \\
&= p_{k,0} x_k + (1 - p_{k,0})(I - L_k C) x_k \\
&\quad - p_{k,0} \bar{x}_k - (1 - p_{k,0})(I - L_k C) \bar{x}_k - L_k \sum_{j=1}^{m_k} (p_{k,j} \hat{v}_{k,j}) \\
&= p_{k,0} (x_k - \bar{x}_k) + (1 - p_{k,0})(I - L_k C) (x_k - \bar{x}_k) - L_k \hat{v}_k \\
&= p_{k,0} \bar{e}_k + (1 - p_{k,0})(I - L_k C) \bar{e}_k - L_k \hat{v}_k
\end{aligned} \tag{2.48}$$

식 (2.48) 을 바탕으로 Updated Variance Matrix 를 유도해보자.

$$\begin{aligned}
\Sigma_k &= \mathbf{E}[e_k e_k^T] = \mathbf{E}[(x_k - \hat{x}_k)(x_k - \hat{x}_k)^T] \\
&= \mathbf{E}[(p_{k,0} \bar{e}_k + (1 - p_{k,0})(I - L_k C) \bar{e}_k - L_k \hat{v}_k) \\
&\quad (p_{k,0} \bar{e}_k + (1 - p_{k,0})(I - L_k C) \bar{e}_k - L_k \hat{v}_k)^T] \\
&= \mathbf{E}[(p_{k,0} \bar{e}_k + (1 - p_{k,0})(I - L_k C) \bar{e}_k - L_k \hat{v}_k) \\
&\quad (p_{k,0} \bar{e}_k^T + (1 - p_{k,0}) \bar{e}_k^T (I - L_k C)^T - \hat{v}_k^T L_k^T)] \\
&= \mathbf{E}[p_{k,0}^2 \bar{e}_k \bar{e}_k^T + (1 - p_{k,0})^2 (I - L_k C) \bar{e}_k \bar{e}_k^T (I - L_k C)^T \\
&\quad + p_{k,0} (1 - p_{k,0}) \bar{e}_k \bar{e}_k^T (I - L_k C)^T \\
&\quad + p_{k,0} (1 - p_{k,0}) (I - L_k C) \bar{e}_k \bar{e}_k^T + L_k \hat{v}_k \hat{v}_k^T L_k^T] \\
&= p_{k,0}^2 \mathbf{E}[\bar{e}_k \bar{e}_k^T] + (1 - p_{k,0})^2 (I - L_k C) \mathbf{E}[\bar{e}_k \bar{e}_k^T] (I - L_k C)^T \\
&\quad + p_{k,0} (1 - p_{k,0}) \mathbf{E}[\bar{e}_k \bar{e}_k^T] (I - L_k C)^T \\
&\quad + p_{k,0} (1 - p_{k,0}) (I - L_k C) \mathbf{E}[\bar{e}_k \bar{e}_k^T] + L_k \mathbf{E}[\hat{v}_k \hat{v}_k^T] L_k^T \\
&= p_{k,0}^2 \bar{\Sigma}_k + (1 - p_{k,0})^2 (I - L_k C) \bar{\Sigma}_k (I - L_k C)^T \\
&\quad + p_{k,0} (1 - p_{k,0}) \bar{\Sigma}_k (I - L_k C)^T \\
&\quad + p_{k,0} (1 - p_{k,0}) (I - L_k C) \bar{\Sigma}_k + L_k \hat{R}_k L_k^T
\end{aligned} \tag{2.49}$$

식 (2.49)를 정리하면 다음과 같다.

$$\begin{aligned} \Sigma_k &= p_{k,0}^2 \bar{\Sigma}_k + (1-p_{k,0})^2 (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k (\mathbf{I} - \mathbf{L}_k \mathbf{C})^\top \\ &\quad + p_{k,0}(1-p_{k,0}) \bar{\Sigma}_k (\mathbf{I} - \mathbf{L}_k \mathbf{C})^\top + p_{k,0}(1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k + \mathbf{L}_k \hat{\mathbf{R}}_k \mathbf{L}_k^\top \end{aligned} \quad (2.50)$$

식 (2.50)에는 문제가 있다. 우리가 $\hat{\mathbf{R}}_k = \mathbf{E}[\hat{\mathbf{v}}_k \hat{\mathbf{v}}_k^\top]$ 를 알 수 없다는 것이다. 따라서, 이것을 $\mathbf{E}[\mathbf{v}_k \mathbf{v}_k^\top]$ 로 대체해서 표시 할 수 있도록 재 표현 해야만 한다.

앞에서 $\mathbf{z}_{k,j} = \mathbf{C}\mathbf{x}_k + \hat{\mathbf{v}}_{k,j}$ 을 정의하면서 처음 $\hat{\mathbf{v}}_{k,j}$ 이 등장하였다. 따라서, $\sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j}$ 와 $\bar{\mathbf{v}}_k$ 의 연관성을 우선적으로 규명하고자 한다.

$$\sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j} = \mathbf{C}\mathbf{x}_k \sum_{j=1}^{m_k} p_{k,j} + \sum_{j=1}^{m_k} (p_{k,j} \hat{\mathbf{v}}_{k,j}) = (1-p_{k,0})\mathbf{C}\mathbf{x}_k + \hat{\mathbf{v}}_k \quad (2.51)$$

우선, 식 (2.51)과 같이 $\sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j}$ 를 $\hat{\mathbf{v}}_k$ 에 대한 식으로 표현하자.

$$\begin{aligned} \bar{\mathbf{v}}_k &= \sum_{j=1}^{m_k} p_{k,j} (\mathbf{z}_{k,j} - \bar{\mathbf{z}}_k) = \sum_{j=1}^{m_k} p_{k,j} \mathbf{z}_{k,j} - \bar{\mathbf{z}}_k \sum_{j=1}^{m_k} p_{k,j} \\ &= (1-p_{k,0})\mathbf{C}\mathbf{x}_k + \hat{\mathbf{v}}_k - (1-p_{k,0})\bar{\mathbf{z}}_k \\ &= (1-p_{k,0})(\mathbf{C}\mathbf{x}_k - \mathbf{C}\bar{\mathbf{x}}_k) + \hat{\mathbf{v}}_k = (1-p_{k,0})\mathbf{C}\bar{\mathbf{e}}_k + \hat{\mathbf{v}}_k \end{aligned} \quad (2.52)$$

식 (2.52)와 같이 $\bar{\mathbf{v}}_k$ 을 $\hat{\mathbf{v}}_k$ 에 대한 식으로 재표현 하자. 이제, 식 (2.51)과 식 (2.52)를 바탕으로 $\mathbf{E}[\mathbf{v}_k \mathbf{v}_k^\top]$ 를 다음과 같이 유도 할 수 있다.

$$\begin{aligned}
\mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T] &= \mathbf{E}\left[\left((1-p_{k,0})\mathbf{C}\bar{\mathbf{e}}_k + \hat{\mathbf{v}}_k\right)\left((1-p_{k,0})\mathbf{C}\bar{\mathbf{e}}_k + \hat{\mathbf{v}}_k\right)^T\right] \\
&= \mathbf{E}\left[\left((1-p_{k,0})\mathbf{C}\bar{\mathbf{e}}_k + \hat{\mathbf{v}}_k\right)\left((1-p_{k,0})\bar{\mathbf{e}}_k^T \mathbf{C}^T + \hat{\mathbf{v}}_k^T\right)\right] \\
&= \left((1-p_{k,0})^2 \mathbf{C} \mathbf{E}[\bar{\mathbf{e}}_k \bar{\mathbf{e}}_k^T] \mathbf{C}^T + \mathbf{E}[\hat{\mathbf{v}}_k \hat{\mathbf{v}}_k^T]\right) \\
&= \left((1-p_{k,0})^2 \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T + \hat{\mathbf{R}}_k\right)
\end{aligned} \tag{2.53}$$

식 (2.53)을 정리하면 다음과 같다.

$$\boxed{\mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T]} = \left((1-p_{k,0})^2 \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T + \hat{\mathbf{R}}_k\right) \tag{2.54}$$

또한 식 (2.41)을 바탕으로 다음이 성립함을 알 수 있다.

$$\boxed{\bar{\Sigma}_k} = \mathbf{L}_k \bar{\mathbf{S}}_k (\mathbf{C}^T)^{-1} \tag{2.55}$$

식 (2.54) 과 식 (2.55)를 바탕으로 식 (2.50)을 재표현해보자.

$$\begin{aligned}
\Sigma_k &= \mathbf{p}_{k,0}^2 \bar{\Sigma}_k + (1-p_{k,0})^2 (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k (\mathbf{I} - \mathbf{L}_k \mathbf{C})^T \\
&\quad + \mathbf{p}_{k,0} (1-p_{k,0}) \bar{\Sigma}_k (\mathbf{I} - \mathbf{L}_k \mathbf{C})^T + \mathbf{p}_{k,0} (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k + \mathbf{L}_k \hat{\mathbf{R}}_k \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0}^2 \bar{\Sigma}_k + (1-p_{k,0})^2 (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - (1-p_{k,0})^2 (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T \\
&\quad + \mathbf{p}_{k,0} (1-p_{k,0}) \bar{\Sigma}_k (\mathbf{I} - \mathbf{L}_k \mathbf{C})^T + \mathbf{p}_{k,0} (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k + \mathbf{L}_k \hat{\mathbf{R}}_k \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0}^2 \bar{\Sigma}_k + (1-p_{k,0})^2 (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - (1-p_{k,0})^2 \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + (1-p_{k,0})^2 \mathbf{L}_k \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T \\
&\quad + \mathbf{p}_{k,0} (1-p_{k,0}) \bar{\Sigma}_k - \mathbf{p}_{k,0} (1-p_{k,0}) \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + \mathbf{p}_{k,0} (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k + \mathbf{L}_k \hat{\mathbf{R}}_k \mathbf{L}_k^T \\
&= \left(\mathbf{p}_{k,0}^2 + \mathbf{p}_{k,0} (1-p_{k,0})\right) \bar{\Sigma}_k + \left((1-p_{k,0})^2 + \mathbf{p}_{k,0} (1-p_{k,0})\right) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k \\
&\quad - \left((1-p_{k,0})^2 + \mathbf{p}_{k,0} (1-p_{k,0})\right) \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + (1-p_{k,0})^2 \mathbf{L}_k \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + \mathbf{L}_k \hat{\mathbf{R}}_k \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - (1-p_{k,0}) \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + (1-p_{k,0})^2 \mathbf{L}_k \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + \mathbf{L}_k \hat{\mathbf{R}}_k \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - (1-p_{k,0}) \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + \mathbf{L}_k \underbrace{\left((1-p_{k,0})^2 \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T + \hat{\mathbf{R}}_k\right)}_{\text{Innovation Variance}} \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - (1-p_{k,0}) \bar{\Sigma}_k \mathbf{C}^T \mathbf{L}_k^T + \mathbf{L}_k \cdot \mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T] \cdot \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - (1-p_{k,0}) \mathbf{L}_k \bar{\mathbf{S}}_k \mathbf{L}_k^T + \mathbf{L}_k \cdot \mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T] \cdot \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - \mathbf{L}_k \cdot \left((1-p_{k,0}) \bar{\mathbf{S}}_k - \mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T]\right) \cdot \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - \mathbf{L}_k \cdot \left(\left(\sum_{j=1}^{m_k} \mathbf{p}_{k,j} (\mathbf{C} \bar{\Sigma}_k \mathbf{C}^T + \mathbf{R})\right) - \mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T]\right) \cdot \mathbf{L}_k^T \\
&= \mathbf{p}_{k,0} \bar{\Sigma}_k + (1-p_{k,0}) (\mathbf{I} - \mathbf{L}_k \mathbf{C}) \bar{\Sigma}_k - \mathbf{L}_k \cdot \left(\left(\sum_{j=1}^{m_k} \mathbf{p}_{k,j} \mathbf{E}[(z_k - \bar{z}_k)(z_k - \bar{z}_k)^T]\right) - \mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T]\right) \cdot \mathbf{L}_k^T
\end{aligned} \tag{2.56}$$

얻어진 식 (2.56)을 정리해서 다시 쓰면 다음과 같다.

$$\Sigma_k = p_{k,0} \bar{\Sigma}_k + (1-p_{k,0})(I-L_k C) \bar{\Sigma}_k - L_k \cdot \left(\sum_{j=1}^{m_k} p_{k,j} (z_{k,j} - \bar{z}_k)(z_{k,j} - \bar{z}_k)^T \right) - \bar{v}_k \bar{v}_k^T \cdot L_k^T \quad (2.57)$$

지금까지 우리는 PDAF의 알고리즘을 자세히 탐험해 보았다.

PDAF는 확률적으로 데이터를 결합시키는 특성 때문에 임의의 Target에 대한 측정값을 다수의 측정값 중에서 신뢰성있게 찾을수 있다. 이러한 특성은 다중 Target 추적 및 추정 기법으로 용이하게 사용된다. 그렇다면, PDAF를 어떻게 IMM-KF기법과 결합 시킬수 있을까? 다음 장에서는 이러한 논점을 논의하고자 한다.

2.6 IMM-PDAF

지금까지 2.2장과 2.3장에서 IMM-KF에 대해서 설명했고, 2.4장과 2.5장에서 PDAF에 대해서 설명했다.

지금까지 설명한 것을 바탕으로 IMM-PDAF를 설명하고자 한다. 앞에서도 설명했지만, 지금까지 개발된 다중 표적 추적 알고리즘들 중에서 가장 실시간성을 유지하면서, 그 정확성에 신뢰 할 수 있는 것은 IMM-PDAF가 추천되고 있는 실정이다.[17-19]




Figure 2-17 IMM-PDAF의 다이어그램.

IMM-PDAF의 특성을 정리해 보자.

- 다중 모델로 임의의 움직임을 추적하는데 효과적이다.
- 관심표적의 측정값을 다수의 측정값들 중에서 찾는다.
- 센서의 간헐적 표적측정실패에 대해서 융통성있게 대처한다.
- 확률기반 추적 알고리즘으로써 그 신뢰성을 보장받을수 있다.

그럼, PDAF를 어떻게 IMM-KF와 연결시킬수 있을까? 방법은 간단하다. IMM-KF의 Filter Bank에서 Kalman Filter를 사용하던 것을 PDAF로 교체해서 사용하면 된다. 하지만, 이때, 주의해야 하는 것 있다. Mode Estimation단계에서 Mode update값을 찾을 때 IMM-KF때와 조금 달라진다. 앞으로 이부분에 대해서 설명하겠다.

2.6.1 Mode Estimation Step.

2.3.5장에서 Mode Estimation Step에 대한 기본설명은 했다. 여기선 다중 측정값이 존재할 때 어떻게 μ_k^i 를 구하는지를 알아보고자 한다. 앞에서 설명했듯이 우리는 μ_k^i 을 구하기 앞서서 $\Lambda_k^i(z_k)$ 를 먼저 유도하였다. 여기서도 $\Lambda_k^i(z_k)$ 를 우선 유도해 보고자 한다.

< 해석적 풀이 >

$\mu_k^i = P(m_k^i | z_k)$ 의 의미는 k번째 센서 측정을 실시 했을 때, 결과값이 i번째 model로 선택될 확률을 나타낸다.

이것을 바꾸어서 해석해 보면 다음과 같습니다. k번째에 센서로 측정한 값들 중 Gating을 통과한 측정값들은 model i의 예측 측정값 $\bar{z}_k^i$ 로부터 어떠한 분포확률의 합의 값을 가지고 흐트러져 있는가

로 해석 할 수 있다. 그럼, 측정값들의 분포확률의 합은 어떻게 표현할수 있을까? 그 해답은 이미 PDAF의 Conditional Probability인 식(2.35)에서 풀었다. 이것을 바탕으로 다시 정리하면, 다음과 같다.

$$\begin{aligned}\Lambda_k^i(z_k) &= \left(\sum_{j=1}^{m_k} \lambda^{(m_k-1)} \cdot \frac{N(z_{k,j}; \bar{z}_k, S_k)}{P_G} \cdot P_D \cdot P_G \right) + \lambda^{(m_k)} \cdot (1 - P_D \cdot P_G) \\ &= \left(\lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D} + \sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k, S_k) \right) \cdot P_D \cdot \lambda^{(m_k-1)}\end{aligned}\quad (2.58)$$

$$\boxed{\Lambda_k^i(z_k) = \left(\lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D} + \sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k, S_k) \right) \cdot P_D \cdot \lambda^{(m_k-1)}} \quad (2.59)$$

이렇게 구해진 식(2.59)를 기존에 있던 식(2.18)에 적용해 보자.

이렇게 해서 구한 μ_k^i 이 다중 측정값을 이용한 Mode Estimation 단계이다.

제 3 장 MMPDAM을 활용한 센서 퓨전.

지금까지 기존에 존재하는 다중 표적 추적 알고리즘으로 대표적인 IMM-PDAF를 알아보았다. 앞에서 말했듯이 정확성, 신뢰성, 융통성등 여러 측면에서 훌륭한 알고리즘이다. 하지만, 이것을 실제 필드에서 적용하면, 아직 해결해야하는 문제점들을 볼수있다.

다음은 IMM-PDAF에 3개의 Model을 적용하여서 사용했을 때 드러난 문제점을 기술하였다.

- 한 개의 Target을 1번 추적하는데 평균 11ms가 소요된다.
- Filter Bank의 PDAF에 Filter방식을 바꾸어 볼수가 없다.
(각 Model별로 서로 다른 Filter특성을 적용 할 수 없다.)
- IMM-PDAF의 연산량 중 66.5%정도가 PDAF에 과중된다.

위에서 나열했듯이 평소 차량을 대상으로 다중 표적을 추적한다면, 10~20대 정도를 생각하게 된다. 하지만, IMM-PDAF를 적용하여서 10개의 표적을 추적한다고 하면, 대략 110ms정도로써 실시간 추적이라고 보기엔 어려워 보이는 현실에 봉착하게 된다.

그래서, 본 논문은 이러한 문제점에 대응하고자 다음과 같은 새로운 알고리즘을 제안하고자 한다.




Figure 3-1 IMM-PDAMF의 다이어그램.

Figure 3-1에서 단연 돋보이는 곳은 MMPDAM이란 곳이다.

다음 장부터 자세히 설명하겠지만, MMPDAM은 풀어 쓰면 다중 모델 기반의 확률적 데이터 결합 기법이다.

바로 이 부분이 제가 새롭게 제안하는 구체적인 알고리즘이고 MMPDAM으로 연산량을 기존보다 평균 39.6% 감쇠시켰으며, 정확성은 소폭 약 4%정도 향상 시켰다. 또한 두드러진 장점은 PDAF의 문제점인 PDA기법과 Filter기법을 일체화 시킨점을 분리시켰다는 것이다. 이것은 향후 Model별로 가장 적합한 Filter선정을 통해서 지금보다 정확성을 향상 시킬 것으로 기대된다.

3.1 다중 모델 기반의 확률적 데이터 결합 기법

이번 장에서는 IMM-PDAMF의 핵심 알고리즘인 MMPDAM의 동작 방식을 알기 쉽게 설명하기 위한 부분입니다. 가급적 여기서 수식을 배제하고 그림으로 설명하겠습니다.




Figure 3-2 MMPDAM의 알고리즘 모식도.

Figure 3-2의 MMPDAM의 핵심 아이디어는 다음과 같다.

그 동안 각 Model별로 따로 실시되었던 PDAF를 Model 한 개의 입장에서 바라볼것이 아니라, 여러 모델을 사용하는 만큼 다중의 모델상태에서 PDA를 시켜보는 것이 어떠냐 하는 발상의 전환입니다.

그럼, 어떻게 해서 다중 모델 상태에서 PDA를 시킬까?

- Gating Step.

Gating에서는 각 모델이 가진 유효영역 중 어느 한 유효영역에만 속하여도 그 측정값을 Gating을 통과한 측정값으로 간주한다. 따라서, 각 모델별로 측정값 개수만큼 연산을 했던것을 측정값 개수만큼만 시행하면 된다는 장점을 가지게 된다.

- Calculation Conditional Probability Step.

앞에서도 설명했듯이 Calculation Conditional Probability는 각 측정값이 실제 Target의 측정값으로써 얼마만큼의 가능성이 있는지를 확률적으로 표현하는 것이다.

전 여기서, Gating을 통과한 모든 측정값들을 대상으로 각 Model별 Conditional Probability를 계산해야 한다고 생각했다. 다만, 각 Model이 실제 Target의 움직임에 얼마나 유사성을 가지는지 그 확률값인 Mode Update값이 필요하다고 생각했다. 그래서, 전반적으로 기존 PDAF를 각 Model별로 실시하던 것보다 더욱 강하게 PDA를 시키는 결과가 되었습니다. 이것은 IMM-PDAMF가 IMM-PDAF보다 정확성을 향상 시킬수 있었던 이유라고 생각한다.

– Updated Measure Step.

Updated Measure는 앞에서 구한 Conditional Probability값과 Model 통합형 예측 측정값을 이용하여서 실제 측정값에 가장 가까운 측정값 상태 벡터를 도출한다. 또한, 수학적 유도를 통해서 측정값 Variance Matrix를 구하게 된다.

지금까지 IMM-PDAMF의 핵심 알고리즘인 MMPDAM의 아이디어 및 순서 절차를 알아보았다. 다음 장은 MMPDAM의 자세한 동작 방법을 알아보도록 하자.

3.2 MMPDAM의 기초 이론

앞장에서 설명한 MMPDAM을 이번장에서는 수식적으로 구체적인 방법을 알아보고자 한다.




Figure 3-3 MMPDAM 알고리즘.

Figure 3-3에서 보는것과 같이 입력으로 각 모드별 Prediction 된 측정값($\bar{z}_k^j$)과 그것의 Innovation 분산값($\bar{S}_{k,R}^j$)을 받는다. 이때,

Innovation 분산값($\mathbf{S}_k^j$)에서 측정값의 noise 분산값($\mathbf{R}_k$)을 제외한 형태를 취한다. 그럼, 단계별로 구체적으로 알아보도록 하자.

3.2.1 Gating Step.

다중 모델 기반의 Gating은 Model별로 구분할 필요없이 어느한 Model의 유효영역안에 존재하는 측정값은 Gating을 통과한 측정값으로 인정하고 추후의 모든 처리에서 동일하게 취급하는 형태이다.

기본 Gating의 원리는 PDAF와 동일하게 Mahalanobis distance 값을 구하고 그것이 기준거리 G 보다 작은 경우의 측정값을 Gating을 통과한 측정값으로 분류하는 작업이다. 또한, 여기서 사용한 G 값은 chi-table을 참조하면 얻을수 있다. 참조하기 위해서 필요한 입력요소는 Gating이 사용된 유효한 차원수(n)과 유효영역(VG)안에 측정값이 존재하지 않을 확률($1-P_G$)이 된다.

이 단계는 수식적으로는 2.5.3장에서 설명한 내용과 동일하다.

다만 Software Skill면에서 좀더 빠른 처리방식을 채택할수 있단 장점을 가진다.

3.2.2 Calculation Conditional Probability Step.

다중 모델 기반의 Calculation Conditional Probability단계는 Gating을 통과한 측정값들 각각이 Target의 실제 측정값으로써 얼마의 확률을 가질 것인지를 계산한다란 측면에서 기존의 PDAF와 동일하다. 하지만, 다음과 같은 특성 및 처리방식의 차이점이 있다.

- 다중 모델상의 확률적 연관성을 측정값들과 긴밀히 이루었다.
- 위 특징을 위해서 자연스레 Mode Update가 이루어 진다.

- Model별로 동일한 측정값군을 통해서 확률계산을 한다.

< 해석적 접근 >

PDAF의 식(2.28)과 동일한 해석적 접근으로 시작하므로 설명을 생략합니다. 따라서, 우리가 구해야 하는 식은 식(2.30)으로 다음과 같이 다시 적어 봅니다.

$$p_{k,j} = \frac{P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)}{\sum_{j=0}^{m_k} P(z_{k,g} | T_{k,j}, Z_k)P(T_{k,j} | Z_k)} \quad (3.1)$$

식(3.1)을 구성하는 각 확률요소를 구해보도록 하겠습니다.

< $j \neq 0, P(T_{k,j} | Z_k)$ 유도. >

의미 : k번째까지 측정했을 때, Gating을 통과한 측정값들 중 j번째 측정값이 Target의 측정값이 될 확률을 뜻한다.

풀이 : 식(2.31)에서 나와있는 방식과 동일하므로 설명은 생략하겠습니다.

$$j \neq 0, P(T_{k,j} | Z_k) = P_D P_G \quad (3.2)$$

< $j = 0, P(T_{k,j} | Z_k)$ 유도. >

의미 : k번째까지 측정했을 때, Gating을 통과한 측정값들 중 어느 측정값도 Target의 측정값이 아닐 확률을 뜻한다.

풀이 : 여기서도 식(2.32)에서 나와있는 방식과 동일하므로 설명은 생략 하겠습니다.

$$j = 0, P(T_{k,j} | Z_k) = 1 - P_D P_G \quad (3.3)$$

< $j \neq 0, P(z_{k,g} | T_{k,j}, Z_k)$ 유도. >

의미 : k번째까지 측정했고, Gating을 통과한 측정값들 중 j번째 측정값이 Target의 측정값이라고 했을 때, Gating을 통과한 측정값들의 그룹확률을 뜻한다.

풀이 : 우선, PDAF의 가정을 떠올려 보자. Gating을 통과한 측정값들 중에서는 현재 찾고자하는 Target 이외의 Target의 측정값은 존재하지 않는다. 이것은 바꾸어 말하면, Gating을 통과한 측정값들은 모두 Clutter이거나 혹은 Target의 측정값을 포함한 Clutter들이란 뜻을 가진다. 또한, 이러한 측정값들은 각 Mode별 Update 확률값을 적용하여서 전체적으로 평균값을 구하게 된다.

위 풀이를 수식으로 표현하면 다음과 같다.

$$j \neq 0, P(z_{k,g} | T_{k,j}, Z_k) = \lambda^{(m_k-1)} \cdot \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{P_G} \quad (3.4)$$

- 가정 : Gating을 통과한 측정값들 중에는 다른 Target의 측정값이 포함되지 않는다.
- 가정 : Target의 측정값이 아닌 것은 모두 Clutter이고, 유효범위 내부에서는 Uniform Distribution한 분포를 가진다.
- 가정 : 구해진 Clutter의 밀도(λ_k)는 각 Model별 Clutter의 밀도(λ_k^j)의 평균값으로써, Model별 Clutter 밀도값이 크게 다르지 않음을 전제로 한다.

< $j = 0, P(z_{k,g} | T_{k,j}, Z_k)$ 유도. >

의미 : k번째까지 측정했고, Gating을 통과한 측정값들 중 어느 측정값도 Target의 측정값이 될 수 없을때, Gating을 통과한 측정값들의 그룹확률을 뜻한다.

풀이 : 식(3.4)에 적용된 가정은 여기서도 동일하게 적용된다.
그리고, Gating을 통과한 모든 측정값은 Clutter가 됨을 알 수 있다.

$$j = 0, P(z_{k,g} | T_{k,j}, Z_k) = \lambda^{(m_k)} \quad (3.5)$$

지금까지 식(3.1)의 구성요소를 풀어 보았다.

이제 각 풀이를 식(3.1)에 적용하여서 답을 유도해 보자.

< $j \neq 0, p_{k,j}$ 의 값은? >

의미 : j번째 측정값이 Target의 측정값일 객관적인 확률.

$$\begin{aligned} p_{k,j} &= \frac{\lambda^{(m_k-1)} \cdot \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{P_G} \cdot P_D \cdot P_G}{\left(\sum_{j=1}^{m_k} \lambda^{(m_k-1)} \cdot \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{P_G} \cdot P_D \cdot P_G \right) + \lambda^{(m_k)} \cdot (1 - P_D \cdot P_G)} \\ &= \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{\left(\sum_{j=1}^{m_k} \sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i \right) + \lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D}} \\ &= \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{\sum_{i=1}^r \left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k^i, S_k) \right) \cdot \mu_k^i + \lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D} \cdot \sum_{i=1}^r \mu_k^i} \\ &= \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{\sum_{i=1}^r \left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k^i, S_k) + \lambda \cdot \frac{(1 - P_D \cdot P_G)}{P_D} \right) \cdot \mu_k^i} \quad (3.6) \end{aligned}$$

따라서, 식 (3.6)을 정리하면 다음과 같다.

$$p_{k,j} = \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{\sum_{i=1}^r \left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k^i, S_k) + \lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D} \right) \cdot \mu_k^i} \quad (3.7)$$

< j=0, p_{k,j}의 값은? >

의미 : 어느 측정값도 Target의 측정값이 아닐 확률.

$$\begin{aligned} p_{k,0} &= \frac{P(z_{k,0} | T_{k,0}, Z_k) P(T_{k,0} | Z_k)}{\sum_{j=0}^{m_k} P(z_{k,j} | T_{k,j}, Z_k) P(T_{k,j} | Z_k)} \\ &= \frac{\lambda^{(m_k)} \cdot (1-P_D \cdot P_G)}{\left(\sum_{j=1}^{m_k} \lambda^{(m_k-1)} \cdot \frac{\sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i}{P_G} \cdot P_D \cdot P_G + \lambda^{(m_k)} \cdot (1-P_D \cdot P_G) \right)} \\ &= \frac{\lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D}}{\left(\sum_{j=1}^{m_k} \sum_{i=1}^r N(z_{k,j}; \bar{z}_k^i, S_k) \cdot \mu_k^i + \lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D} \right)} \\ &= \frac{\lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D}}{\sum_{i=1}^r \left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k^i, S_k) + \lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D} \right) \cdot \mu_k^i} \quad (3.8) \end{aligned}$$

식 (3.8)을 정리하면 다음과 같다.

$$p_{k,0} = \frac{\lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D}}{\sum_{i=1}^r \left(\sum_{j=1}^{m_k} N(z_{k,j}; \bar{z}_k^i, S_k) + \lambda \cdot \frac{(1-P_D \cdot P_G)}{P_D} \right) \cdot \mu_k^i} \quad (3.9)$$

그런데 여기서 사용된 Mode Update는 어떻게 해서 구하는 것일까? 이것은 2.6.1장의 IMM-PDAF에서 계산한 식(2.59)를 이용해서 측정값들의 관계정도를 구하고 이것을 다시 식(2.18)에 적용하면 μ_k^i 를 구할수 있다.

이렇게 구해진 확률 값인 식(3.7)과 식(3.9)를 Conditional Probability라고 부른다. Conditional Probability는 다음 단계인 Updated Measure에서 Target의 실제 측정값과 가장 유사한 측정값을 구하기 위해서 필요한 요소이다.

3.2.3 Updated Measure Step.

Update Measure에서는 Model별 예상 측정값을 통합한 단일 예상 측정값($\bar{z}_k$)을 구하고, 이것을 바탕으로 통합된 예측 Innovation 값(∇_k)을 구한다. 이때, 전 단계에서 구한 Conditional Probability를 적용한다. 이후에는 이것들을 바탕으로 Updated된 Target의 측정값($\hat{z}_k$)과 그것의 Error Variance Matrix($\hat{R}_k$)를 구하게 된다.

$\hat{z}_k$ 와 $\hat{R}_k$ 이 우리가 구하고자 한 MMPDAM의 목적이 된다.

그럼, 이제 순서대로 구해 보도록 하자.

< $\bar{z}_k$ 를 계산하자. >

전 단계에서 구한 Mode Update(μ_k^j)를 이용하여서 Model별 예측 측정값들의 평균을 구하자.

$$\bar{z}_k = \sum_{j=1}^r \bar{z}_k^j \cdot \mu_k^j \quad (3.10)$$

< $\bar{\mathbf{v}}_k$ 를 계산하자. >

전 단계에서 구한 Conditional Probability와 $\bar{\mathbf{z}}_k$ 를 이용하여서 Innovation의 평균을 구해보자.

$$\bar{\mathbf{v}}_k = \sum_{i=1}^{m_k} p_{k,i} (\mathbf{z}_{k,(i)} - \bar{\mathbf{z}}_k) \quad (3.11)$$

- $\mathbf{z}_{k,(i)}$: Gating을 통과한 측정값들 중 i 번째 측정값이다.

< $\hat{\mathbf{z}}_k$ 을 구해보자. >

식(3.11)을 식(2.39)에 의해서 다음과 같이 표현할수 있다.

$$\mathbf{z}_k - \bar{\mathbf{z}}_k \approx \sum_{i=1}^{m_k} p_{k,i} (\mathbf{z}_{k,(i)} - \bar{\mathbf{z}}_k) \quad (3.12)$$

식(3.12)에서 우린 $\mathbf{z}_k$ 를 알수가 없으므로 대신 $\hat{\mathbf{z}}_k$ 로 대체해서 $\hat{\mathbf{z}}_k$ 를 구하도록 하자.

$$\hat{\mathbf{z}}_k - \bar{\mathbf{z}}_k = \bar{\mathbf{v}}_k = \sum_{i=1}^{m_k} p_{k,i} (\mathbf{z}_{k,(i)} - \bar{\mathbf{z}}_k) \quad (3.13)$$

$$\begin{aligned} \hat{\mathbf{z}}_k &= \sum_{i=1}^{m_k} p_{k,i} (\mathbf{z}_{k,(i)} - \bar{\mathbf{z}}_k) + \bar{\mathbf{z}}_k \\ &= \sum_{i=1}^{m_k} p_{k,i} \cdot \mathbf{z}_{k,(i)} + \bar{\mathbf{z}}_k - \bar{\mathbf{z}}_k \cdot \sum_{i=1}^{m_k} p_{k,i} \\ &= \sum_{i=1}^{m_k} p_{k,i} \cdot \mathbf{z}_{k,(i)} + \bar{\mathbf{z}}_k - \bar{\mathbf{z}}_k \cdot (1 - p_{k,0}) \\ &= \sum_{i=1}^{m_k} p_{k,i} \cdot \mathbf{z}_{k,(i)} + p_{k,0} \cdot \bar{\mathbf{z}}_k \end{aligned} \quad (3.14)$$

따라서, 식(3.14)을 정리하면 다음과 같다.

$$\boxed{\hat{\mathbf{z}}_k = \sum_{i=1}^{m_k} p_{k,i} \cdot \mathbf{z}_{k,(i)} + p_{k,0} \cdot \bar{\mathbf{z}}_k} \quad (3.15)$$

< $\hat{\mathbf{R}}_k$ 을 구해보자. >

$\hat{\mathbf{z}}_k$ 를 다음과 같이 정의 할 수 있다.

$$\hat{\mathbf{z}}_k = \mathbf{C}_k \cdot \mathbf{x}_k + \hat{\mathbf{v}}_k \quad (3.16)$$

식 (3.16) 과 식 (3.13) 을 바탕으로 $\hat{\mathbf{R}}_k$ 를 구해보면 다음과 같다.

$$\begin{aligned} \hat{\mathbf{R}}_k &= \mathbf{E}[\hat{\mathbf{v}}_k \cdot \hat{\mathbf{v}}_k^T] = \mathbf{E}[(\hat{\mathbf{z}}_k - \mathbf{C}_k \cdot \mathbf{x}_k)(\hat{\mathbf{z}}_k - \mathbf{C}_k \cdot \mathbf{x}_k)^T] \\ &= \mathbf{E}[(\bar{\mathbf{z}}_k + \bar{\mathbf{v}}_k - \mathbf{z}_k + \mathbf{v}_k)(\bar{\mathbf{z}}_k + \bar{\mathbf{v}}_k - \mathbf{z}_k + \mathbf{v}_k)^T] \\ &= \mathbf{E}[(\mathbf{v}_k + \bar{\mathbf{v}}_k - (\mathbf{z}_k - \bar{\mathbf{z}}_k))(\mathbf{v}_k + \bar{\mathbf{v}}_k - (\mathbf{z}_k - \bar{\mathbf{z}}_k))^T] \\ &= \mathbf{R}_k + \mathbf{E}[\bar{\mathbf{v}}_k \cdot \bar{\mathbf{v}}_k^T] + \underbrace{\sum_{j=1}^r \left\{ \bar{\mathbf{S}}_k^j + (\bar{\mathbf{z}}_k^j - \bar{\mathbf{z}}_k)(\bar{\mathbf{z}}_k^j - \bar{\mathbf{z}}_k)^T \right\} \cdot (\mu_k^j)^2}_{\bar{\mathbf{S}}_k = \mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T]} \quad (3.17) \\ &\quad - \left(\mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)\mathbf{v}_k^T] + \mathbf{E}[\mathbf{v}_k(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T] \right) \\ &\quad - \left(\mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)\bar{\mathbf{v}}_k^T] + \mathbf{E}[\bar{\mathbf{v}}_k(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T] \right) \\ &\quad + \left(\mathbf{E}[\mathbf{v}_k\bar{\mathbf{v}}_k^T] + \mathbf{E}[\bar{\mathbf{v}}_k\mathbf{v}_k^T] \right) \end{aligned}$$

식 (3.17) 에서 $\mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T]$ 를 다음과 같이 정의 하자.

$$\boxed{\bar{\mathbf{S}}_k = \mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T] = \sum_{j=1}^r \left\{ \bar{\mathbf{S}}_k^j + (\bar{\mathbf{z}}_k^j - \bar{\mathbf{z}}_k)(\bar{\mathbf{z}}_k^j - \bar{\mathbf{z}}_k)^T \right\} \cdot (\mu_k^j)^2} \quad (3.18)$$

식 (3.18) 에 따라서, 식 (3.17) 을 다시 쓰면, 다음과 같다.

$$\begin{aligned} \hat{\mathbf{R}}_k &= \mathbf{R}_k + \mathbf{E}[\bar{\mathbf{v}}_k \cdot \bar{\mathbf{v}}_k^T] + \bar{\mathbf{S}}_k \\ &\quad - \left(\mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)\mathbf{v}_k^T] + \mathbf{E}[\mathbf{v}_k(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T] \right) \\ &\quad - \left(\mathbf{E}[(\mathbf{z}_k - \bar{\mathbf{z}}_k)\bar{\mathbf{v}}_k^T] + \mathbf{E}[\bar{\mathbf{v}}_k(\mathbf{z}_k - \bar{\mathbf{z}}_k)^T] \right) \\ &\quad + \left(\mathbf{E}[\mathbf{v}_k\bar{\mathbf{v}}_k^T] + \mathbf{E}[\bar{\mathbf{v}}_k\mathbf{v}_k^T] \right) \quad (3.19) \end{aligned}$$

여기서, 식(3.19)를 풀기 위해서 발상의 전환이 다시 한번 필요하다. 식(2.54)를 아래와 같이 다시 한번 써보자.

$$\mathbf{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T] = ((1-p_{k,0})^2 \mathbf{C} \bar{\Sigma}_k \mathbf{C}^T + \hat{\mathbf{R}}_k) \quad (3.20)$$

- $\hat{\mathbf{R}}_k$: $\hat{\mathbf{z}}_k = \mathbf{C}_k \mathbf{x}_k + \hat{\mathbf{v}}_k$ 일 때, $\mathbf{E}[\hat{\mathbf{v}}_k \hat{\mathbf{v}}_k^T]$ 이다.

식(3.20)을 해석적으로 구체화 시키기 쉽게 하기 위해서 Figure 3-4와 같이 모식도를 그려보았다.




Figure 3-4 $\mathbf{v}_k$, $\hat{\mathbf{v}}_k$ 과 $\bar{\mathbf{v}}_k$ 의 관계도

Figure 3-4은 $\mathbf{v}_k$, $\hat{\mathbf{v}}_k$ 과 $\bar{\mathbf{v}}_k$ 의 관계를 도식적으로 보여준 것이다. 여기서, $p_{k,0}$ 의 값이 0으로 가고 $p_{k,i}$ 를 가지는 측정값의 숫자가 적어질수록 $\hat{\mathbf{z}}_k$ 는 $\mathbf{z}_k$ 쪽으로 가까이 간다고 신뢰 할 수 있다.

또한, $p_{k,0}$ 의 값이 1으로 갈수록 $\hat{\mathbf{z}}_k$ 는 $\bar{\mathbf{z}}_k$ 쪽으로 가까이 간다고 신뢰 할 수 있다.

이 해석적 풀이를 식(3.20)적용해 보면 다음과 같다.

- $p_{k,0} = 0$ 이면, $\hat{\mathbf{R}}_k = \mathbf{R}_k$
- $p_{k,0} = 1$ 이면, $\hat{\mathbf{R}}_k = 0$

이러한 논리를 $\bar{\mathbf{v}}_k$ 에 적용하면 다음과 같은 특성을 얻을수 있다.

$$\bar{\mathbf{v}}_k \begin{cases} \cong \mathbf{z}_k - \bar{\mathbf{z}}_k & \text{if } p_{k,0} = 0 \\ = 0 & \text{if } p_{k,0} = 1 \end{cases} \quad (3.21)$$

이것을 바탕으로 다음과 같이 $\bar{\mathbf{v}}_k$ 를 간략화 시켜보자.

$$\bar{\mathbf{v}}_k = (1 - p_{k,0}) \cdot (\mathbf{z}_k - \bar{\mathbf{z}}_k) \quad (3.22)$$

그럼, 식(3.22)를 바탕으로 식(3.19)의 구성요소들을 풀어보자.

$$\mathbb{E}[\bar{\mathbf{v}}_k \bar{\mathbf{v}}_k^T] = (1 - p_{k,0})^2 \cdot \bar{\mathbf{S}}_k \quad (3.23)$$

$$\mathbb{E}[(\mathbf{Z}_k - \bar{\mathbf{Z}}_k) \bar{\mathbf{v}}_k^T] = (1 - p_{k,0}) \cdot \bar{\mathbf{S}}_k \quad (3.24)$$

$$\mathbb{E}[(\mathbf{Z}_k - \bar{\mathbf{Z}}_k) \mathbf{v}_k^T] = \mathbf{R}_k \quad (3.25)$$

$$\mathbb{E}[\bar{\mathbf{v}}_k \mathbf{v}_k^T] = (1 - p_{k,0}) \cdot \mathbf{R}_k \quad (3.26)$$

구해진 식(3.23 ~ 3.26)을 적용하여서 식(3.19)을 풀어보자.

$$\begin{aligned} \hat{\mathbf{R}}_k &= \mathbf{R}_k + (1 - p_{k,0})^2 \cdot \bar{\mathbf{S}}_k + \bar{\mathbf{S}}_k - (\mathbf{R}_k + \mathbf{R}_k) \\ &\quad - ((1 - p_{k,0}) \cdot \bar{\mathbf{S}}_k + (1 - p_{k,0}) \cdot \bar{\mathbf{S}}_k) \\ &\quad + ((1 - p_{k,0}) \cdot \mathbf{R}_k + (1 - p_{k,0}) \cdot \mathbf{R}_k) \\ &= p_{k,0}^2 \cdot \bar{\mathbf{S}}_k + \mathbf{R}_k - 2p_{k,0} \cdot \mathbf{R}_k \end{aligned} \quad (3.27)$$

식(3.27)을 정리하면 다음과 같다.

$$\boxed{\hat{\mathbf{R}}_k = p_{k,0}^2 \cdot \bar{\mathbf{S}}_k + \mathbf{R}_k - 2 \cdot p_{k,0} \cdot \mathbf{R}_k} \quad (3.28)$$

MMPDAM 알고리즘에서는 식(3.15)와 식(3.28)과 같이 $\hat{\mathbf{z}}_k$ 과 $\hat{\mathbf{R}}_k$ 를 구하는 것에 그 목적이 있다.

지금까지 내가 새롭게 제안하는 알고리즘의 설명은 마쳤다.

이제 이러한 알고리즘을 IMM-KF와 어떻게 연결하여서 사용할
 짜를 설명하겠다.

3.3 IMM-PDAMF

3.1장에서 소개한바 있지만, 이곳에서 다시 한번 설명하고자 한다.




Figure 3-5 IMM-PDAMF의 다이어그램.

Figure 3-5는 IMM-PDAMF의 결합상태를 보여주고 있다.

먼저 IMM-KF의 처리과정인 Re-Initialization을 수행한다.

여기서 만들어진 각 Model별 초기화 상태 벡터와 Variance Matrix를 각 Model별로 배치된 Filter의 Prediction 단계로 보낸다.

Filter Prediction후에는 각 Model별 예측 측정값($\mathbf{z}_k^i$)과 그것의 Innovation Variance($\bar{\mathbf{S}}_k^i$)를 얻을수 있는데, 이것은 MMPDAM의 입력값이 된다. 또한, Re-Initialization단계를 통해서 얻은 Mode Prediction값($\bar{\boldsymbol{\mu}}_k^i$)도 MMPDAM의 입력값이 된다.

MMPDAM의 출력값은 Updated된 측정값의 상태벡터($\hat{\mathbf{z}}_k$)과 그것의 Variance Matrix($\hat{\mathbf{R}}_k$) 그리고 각 모델별 Mode Update값인(μ_k^j)가 나온다. 이렇게 나온 결과값을 기존의 Filter의 Update단계에 넣어주면 각 Model별로 Update된 상태벡터가 나오게 된다.

그럼 최종적으로 Combination으로써 평균을 취하게 되면, 최종 Target의 상태 벡터($\hat{\mathbf{x}}_k$)과 그것의 Covariance값(Σ_k)을 얻을수 있다.

제 4 장 시뮬레이션

4.1 시뮬레이션 환경 소개

4.1.1 시뮬레이션 환경

본 논문에서 제안하는 IMM-PDAMF와 IMM-PDAF의 연산량의 비교를 보다 명확하게 보여주기 위해서 Single Core를 사용하는 컴퓨터를 사용했다. 다음장에서는 각각의 경우를 예로해서 IMM-PDAMF와 IMM-PDAF기법을 각각 9.333초 동안 실험하고 알고리즘의 동작 주기는 10Hz로 했다. 이때, 외부센서는 Single Image, Laser, Radar등 이고 이들의 측정 노이즈는 $[0.3 \ 1.0]$, $[0.4 \ 0.2 \ 2.3 \ 1.3]$, $[0.2 \ 0.2 \ 1.3 \ 1.3]$ 이다. 각 센서의 측정 주파수는 각각 1Hz, 30Hz, 10Hz로 서로 비동기적으로 측정값을 제공한다. 그리고, 이들 센서들이 모두 90%의 확률로 Target을 측정한다고 설정 한다. 마지막으로 Clutter의 분포는 Uniform Distribution이라고 가정 하고 Clutter밀도를 $0.001EA/m^2$ 로 설정 했다.

4.2 각 경우별 시뮬레이션

4.2.1 차선을 바꾸는 경우의 표적 추적.

물체가 운동 코스를 변화시키는 동작으로써, 물체가 40Km/h의 등속 직선 운동을 진행하다 5deg/sec의 각속도를 가지고 등속 원운동을 1초동안 하고, 다시 -5deg/sec의 각속도를 가지고 등속 원운동을 1초동안 하고, 그 이후에는 다시 40Km/h의 등속 직선 운동을 하는 경우이다.




Figure 4-1 차선 변경을 추적한 모습.

Figure 4-1은 IMM-PDAMF알고리즘을 적용하여서 물체를 추적하는 시뮬레이션을 한 결과이다. 이때 파랑색 사각형은 물체가 지나간 실제흔적이다. 그리고, 빨강색 큰원이 파랑색 사각형을 따라가는 것을 볼수있다. 이때 빨강색 큰원이 IMM-PDAMF를 알고리즘을 적용한 결과이다. 위 그림으로는 얼마나 잘 쫓아가는지 알기 힘들므로 다음과 같이 표로 작성해 보았다.




Figure 4-2 IMM-PDAMF를 사용한 정확도 그래프.

Table 4-1 RMSPS의 평균 오차 비교 표.

Tar	Pos	IMM-PDAF (m)	IMM-PDAMF (m)
T1	X	0.098	0.071
	Y	0.210	0.177
RMSPS		0.274	0.190

Figure 4-2는 IMM-PDAMF기법을 적용했을때의 추적된 RMSPS의 값을 나타낸다. Table 4-1를 보면 각 기법들을 적용했을때의 RMSPS 평균값을 나타낸다. 표를 보면 IMM-PDAF를 했을 때 보다 IMM-PDAMF기법을 적용했을때가 약 8cm가량 더 정확성이 높아짐을 알 수 있다.




Figure 4-3 IMM-PDAF와 IMM-PDAMF의 연산량 그래프.

Table 4-2 평균 연산 시간 비교 표.

	IMM-PDAF	IMM-PDAMF
Cost Time	11.857msec	7.232msec

Figure 4-3와 Table 4-2은 IMM-PDAF와 IMM-PDAMF를 적용했을 때의 연산량을 비교한 것이다. Figure 4-3는 각 기법들을 0.1초 간격으로 실행했을 때 매번 걸린 연산량을 검출하여서 실시간 그래프로 보여준 것이다. Table 4-2은 각 기법 별로 평균 연산 시간을 계산하여서 보여준 것이다. 이것에 따르면, IMM-PDAMF의 연산량이 IMM-PDAF의 연산량보다 39.0% 감소됨을 알수있다.

4.2.2 U-turn하는 경우의 표적 추적.

물체가 U-turn하는 동작으로써, 물체가 20Km/h의 등속 직선운동을 진행하고 180deg/sec의 각속도를 가지고 등속 원운동을 1초 진행하고, 다시 20Km/h의 등속 직선 운동을 한다.




Figure 4-4 U-turn하는 차량을 추적한 모습.




Figure 4-5 IMM-PDAMF를 사용한 정확도 그래프.

Table 4-3 RMSPS의 평균 오차 비교 표.

Tar	Pos	IMM-PDAF (m)	IMM-PDAMF (m)
T1	X	0.084	0.093
	Y	0.137	0.144
RMSPS		0.161	0.171

Figure 4-4은 Figure 4-1과 동일한 표기 방식으로 되어있다. Table 4-3의 RMSPS 평균값을 비교해 보면, IMM-PDAF기법의 RMSPS값이 IMM-PDAMF기법보다 약 1cm정도 정확성이 높다. U-turn인 경우 두 기법의 정확성이 거의 비슷함을 알 수 있다.




Figure 4-6 IMM-PDAF와 IMM-PDAMF의 연산량 그래프.

Table 4-4 평균 연산 시간 비교 표.

	IMM-PDAF	IMM-PDAMF
Cost Time	11.642msec	7.236msec

Figure 4-6과 Table 4-4는 Figure 4-3, Table 4-2과 동일한 형식으로 측정한 값이다. U-turn하는 경우, IMM-PDAMF를 사사용했을 때가 IMM-PDAF를 사용할 때보다 37.8%의 연산량을 아낄수 있음을 알았다.

4.2.3 등가속도 직선 운동하는 경우의 표적 추적.

물체가 가속하다가 급 감속하는 동작으로써, 물체가 30Km/h의 속도에서 60Km/h의 속도로 15Km/h^2 의 가속도를 가지고 2초 동안 등가속 직선운동을 한다. 그 후 60Km/h의 등속 직선 운동을 2초 동안 진행하고, -20Km/h^2 의 가속도를 가지고 2초 동안 등가속 직선운동을 한다. 그 후 20Km/h의 등속 직선 운동을 하는 경우이다.




Figure 4-7 등가속도 직선 운동 묘사도.

Figure 4-7는 이번 실험의 표적인 등가속도 직선 운동을 하는 물체의 움직임을 묘사한 그림으로써, 시간대비 속도 그래프로써 표현하였다.




Figure 4-8 등가속도 직선운동을 추적하는 모습.




Figure 4-9 IMM-PDAMF를 사용한 정확도 그래프.

Table 4-5 RMSPS의 평균 오차 비교 표.

Tar	Pos	IMM-PDAF (m)	IMM-PDAMF (m)
T1	X	0.101	0.091
	Y	0.238	0.229
RMSPS		0.259	0.245

Figure 4-8도 앞에서 설명한 Figure 4-1과 동일한 표시법을 사용한다. Table 4-5의 RMSPS 평균값을 비교해 보면, IMM-PDAMF기법의 RMSPS값이 IMM-PDAF기법의 RMSPS값보다 약 1.4cm정도 정확성이 높다. 이로써 등가속도 직선 운동일 경우 두 기법의 정확성이 거의 비슷함을 알 수 있다.




Figure 4-10 IMM-PDAF와 IMM-PDAMF의 연산량 그래프.

Table 4-6 평균 연산시간 비교 표.

	IMM-PDAF	IMM-PDAMF
Cost Time	11.982msec	7.243Msec

Figure 4-10와 Table 4-6은 앞의 경우와 동일한 표기법을 사용한다. 등가속도 직선 운동의 경우, IMM-PDAMF를 사용했을 때가 IMM-PDAF를 사용할 때보다 39.5%의 연산량을 아낄수 있었다.

제 5 장 결 론

어떠한 기계나 혹은 로봇 및 차량이 주변의 환경을 인식하기 위해서는 정확한 추종이 필요하다. 만약, 센서로부터 나오는 데이터에 Clutter가 포함되어 있거나 혹은 원치 않는 대상의 종류들이 많다면, 정확한 추종에 방해가 될 것이다.

본 논문에서는 이러한 추종 기법으로써 IMM-PDAF를 연구하였고 이 기법의 문제점은 연산량이 실시간 처리를 위해서는 부적합하다고 판단하였다. 따라서, 기존의 IMM-PDAF를 수정하여서 IMM-PDAMF란 기법을 새롭게 제안한다.

IMM-PDAMF기법은 IMM-PDAF기법 보다 평균 연산량을 35~40%정도 절약할수 있다. 뿐만 아니라 IMM-PDAMF의 정확성은 IMM-PDAF에 비해서 비슷하거나 약간 향상되었다고 판단 할 수 있다. 또한 개발 초기 기존 IMM-PDAF가 Kalman Filter와 함께 쓸수밖에 없는 알고리즘 구조를 가진점을 개선하기 위해서 IMM-PDAMF 내부에 MMPDAM을 독립적으로 운영 될수 있도록 만듦으로써 Model별로 가장 적합한 Filter를 자유롭게 켜어서 사용할수 있게 되었다. MMPDAM은 입력으로 예상 측정값 상태 벡터와 측정 노이즈가 없는 Innovation Variance Matrix 및 측정 노이즈 분산값을 받아서 출력으로 표적의 Updated 측정값의 상태 벡터와 Updated 측정 노이즈의 분산값을 내놓는다.

IMM-PDAMF기법은 Clutter가 포함된 빠른 다물체 추적 시스템 개발에 사용될 뿐만 아니라, 다양한 Filter를 Model별로 함께 혼합하여서 보다 정확한 추종 시스템 개발에도 사용될 것으로 기대된다.

참고문헌

1. Bar-Shalom, Y., F. Daum, and J. Huang, *The probabilistic data association filter*. Control Systems Magazine, IEEE, 2009. **29**(6): p. 82–100.
2. Rong Li, X. and Y. Bar-Shalom, *Tracking in clutter with nearest neighbor filters: analysis and performance*. Aerospace and Electronic Systems, IEEE Transactions on, 1996. **32**(3): p. 995–1010.
3. Li, X.R., *Tracking in clutter with strongest neighbor measurements. i. theoretical analysis*. Automatic Control, IEEE Transactions on, 1998. **43**(11): p. 1560–1578.
4. Blackman, S.S., *Multiple-target tracking with radar applications*. Dedham, MA, Artech House, Inc., 1986, 463 p., 1986. **1**.
5. Cham, T.J. and J.M. Rehg. *A multiple hypothesis approach to figure tracking*. 1999: IEEE.
6. Oh, S., S. Russell, and S. Sastry. *Markov chain Monte Carlo data association for general multiple-target tracking problems*. 2004: IEEE.
7. Kim, Y.S. and K.S. Hong, *An IMM Algorithm for Tracking Maneuvering Vehicles in an Adaptive Cruise Control Environment*. INTERNATIONAL JOURNAL OF CONTROL AUTOMATION AND SYSTEMS, 2004. **Vol2. No3**.
8. Caveney, D.S., *Multiple target tracking in the adaptive cruise control environment using multiple models and probabilistic data association*. 2001, UNIVERSITY OF CALIFORNIA.
9. 문일기, et al., *다물체 추종 기법을 이용한 충돌 경보*. 한국자동차공학회 2004 년 춘계학술대회 논문집 Volume III, 1535~1540 쪽 (총 6 쪽), 2004.
10. Zhou, T., et al., *Trajectory Generation Model-Based IMM Tracking for Safe Driving in Intersection Scenario*. International Journal. **2011**.
11. Toledo-Moreo, R. and M.A. Zamora-Izquierdo, *IMM-based lane-change prediction in highways with low-cost*

- GPS/INS*. Intelligent Transportation Systems, IEEE Transactions on, 2009. **10**(1): p. 180–185.
12. Abolmaesumi, P. and M. Sirouspour, *An interacting multiple model probabilistic data association filter for cavity boundary extraction from ultrasound images*. Medical Imaging, IEEE Transactions on, 2004. **23**(6): p. 772–784.
 13. KIRUBARAJAN, T. and Y. Bar-Shalom, *Probabilistic data association techniques for target tracking in clutter*. Proceedings of the IEEE, 2004. **92**(3): p. 536–557.
 14. Naidu, V., G. Girija, and J. Raol, *Data association and fusion algorithms for tracking in presence of measurement loss*. IE (I) journal-AS, 2005. **86**: p. 17–28.
 15. Puranik, S.P. and J.K. Tugnait. *On adaptive sampling for multisensor tracking of a maneuvering target using IMM/PDA filtering*. 2005: IEEE.
 16. Schubert, R., E. Richter, and G. Wanielik. *Comparison and evaluation of advanced motion models for vehicle tracking*. 2008: IEEE.
 17. Jo, K., et al. *Integration of multiple vehicle models with an IMM filter for vehicle localization*: IEEE.
 18. Cooperman, R.L. *Tactical ballistic missile tracking using the interacting multiple model algorithm*. 2002: IEEE.
 19. Jilkov, V., D. Angelova, and T.Z.A. Semerdjiev, *Design and comparison of mode-set adaptive IMM algorithms for maneuvering target tracking*. Aerospace and Electronic Systems, IEEE Transactions on, 1999. **35**(1): p. 343–350.

Abstract

Fast Algorithm of Multi-target Tracking using Multi-Model and Probabilistic Data Association.

Kim, Eun Seok
Intelligent Robot Engineering
The Graduate School
Hanyang University

Among the various tracking system available today, the one that offers the most realistic recognition of situation is the asynchronous multi-sensor multi-target real-time tracking system. This study suggests a new algorithm for the real-time multi-target tracking system that becomes the core of such system. This algorithm has significantly improved the load of the previous algorithm, IMM-PDAF, and the convenience by ensuring compatibility of various filters in each model.

In this study, the improvement of accuracy and load of the previous system and the new system was simulated and comparatively analyzed under equal conditions.

감사의 글

갑자기 지난 프로젝트를 성공시키기 위해서 부단히 노력했던 저와 동료들이 생각이 납니다. 표현은 안했지만, 진행도중 성공하기 어려울 것이라고 생각하던 동료들과 그래도 어떻게든 방법을 찾기 위해서 백방으로 연구하던 제 모습이 떠오릅니다.

어려운 프로젝트인 만큼 심적 스트레스가 모두들 많았을 텐데 이 자리를 빌어 수고했고 고맙다란 말을 전하고 싶습니다.

다음은 제 연구를 적극 지지해 주셨던 교수님께 감사인사를 드리고 싶습니다. 바쁘신 와중에도 제가 시도했던 과거 연구업적을 특허출원을 하려고 했을때도 신경써 주셨고, 또한, 이번 SCI 논문 제출도 교수님의 도움이 없었다면, 힘들었을 겁니다.

다음으론 제가 가장 소중한 제 가족들입니다.

물론 제일 고마운분은 제 부모님이십니다. 느즈막하게 공부를 더 하겠다고한 저를 믿어주신 부모님 은혜는 이 논문을 쓰기위한 도전을 가능하게 해주신 분입니다.

그리고, 제가 가장 사랑하는 우리형에게도 고맙습니다. 어렸을적엔 그렇게 많이 싸우던 형이 커서는 이렇게 마음으로 의지할수 있다는 것이 얼마나 좋은지 모릅니다. 그리고, 올해 형이 제게 조카를 선물해 주었습니다. 이름은 김규범입니다. 벌써부터 개구쟁이의 끼를 맘껏 보여주는 조카가 너무 사랑스럽습니다.

그밖에 제 주위의 많은 다른 인연을 가진 분들에게도 감사합니다. 전부 기억할 수는 없지만, 오늘날의 절 있게하기 위해서 도우주신 분들이라고 생각합니다.